

인공지능 데이터 구축·활용 가이드라인

- 문서요약 텍스트 시데이터 -

인공지능 데이터 구축	데이터 획득 및 정제	 
	어노테이션 및 라벨링	
	인공지능 알고리즘 개발	
	응용서비스 개발	
가이드라인 작성	(주)비플라이소프트	최재웅
	(주)위고	김태완
	테스트웍스	김우주
	고려대학교	강필성
	주식회사 에이아이닷엠	최호걸
가이드라인 버전	TextSummaryAIDataGuideline_ver1. / 2020년 7월 22일	

- 목 차 -

1. 데이터 구축 개요
2. 임무 정의
 - 2.1 임무 정의
 - 2.1.1 데이터 구축 목적
 - 2.1.2 데이터 사용자 및 관련 서비스의 수요 관점에서의 요구사항
 - 2.1.3 머신러닝을 통해 해결이 가능한 문제 상황
 - 2.1.4 인공지능 데이터를 적용하여 해결하고자 하는 임무
 - 2.2 데이터 구축 유의사항
 - 2.2.1 인공지능 데이터를 구축하여 배포했을 때 발생가능한 위험요소
 - 2.2.2 데이터 획득에서 검수과정까지 발생가능한 법적 문제
 - 2.2.3 문제 발생을 방지 또는 해결하기 위해 실시한 조치
3. 획득·정제
 - 3.1 원시데이터 선정
 - 3.1.1 원시데이터 특성 현황
 - 3.2 획득·정제 절차
 - 3.2.1 획득 과정 및 절차
 - 3.2.2 원문데이터 획득 절차
 - 3.3 획득·정제 기준
 - 3.3.1 획득·정제 기준
 - 3.3.2 획득·정제 전/후 예시
 - 3.4 획득·정제 조직
 - 3.5 획득·정제 도구
 - 3.6 데이터 전처리
 - 3.6.1 전처리 기준
 - 3.6.2 전처리 도구
 - 3.6.3 전처리 조직
4. 어노테이션/라벨링
 - 4.1 어노테이션/라벨링 절차
 - 4.2 어노테이션/라벨링 기준
 - 4.2.1 어노테이션/라벨링 대상
 - 4.2.2 추출요약의 어노테이션/라벨링 기준
 - 4.2.3 생성요약의 어노테이션/라벨링 기준
 - 4.3 어노테이션/라벨링 조직
 - 4.4 어노테이션/라벨링 도구
 - 4.4.1 도구 개요
 - 4.4.2 주요 도구 기능

5. 검수

5.1 검수 절차

5.2 검수 기준

5.3 검수 조직

5.4 검수 도구

5.5 기타 품질관리 활동

5.6 검수 후 피드백 프로세스


6. 활용

6.1 활용 모델

6.1.1 모델 학습

6.1.2 서비스 활용 시나리오

1. 데이터 구축 개요



[그림 1] 문서요약 텍스트 AI 학습용 데이터 구축 프로세스

2. 임무 정의

2.1 임무 정의

2.1.1 데이터 구축 목적

- ☐ 다양한 한국어 원문 데이터로부터 정제된 추출 및 생성 요약문을 도출하여 검증된 한국어 문서 요약 AI 데이터셋 구축 및 배포
- ☐ 구축된 한국어 문서 요약 AI 데이터셋을 기반으로 추출/생성 요약 AI 알고리즘 개발 및 배포
- ☐ 추출/생성 요약 AI 알고리즘을 이용한 문서 요약 관련 서비스 구현 및 API 배포

2.1.2 데이터 사용자 및 관련 서비스의 수요 관점에서의 요구사항

- ☐ 최근 활발히 활용되고 있는 딥러닝 모델을 포함한 AI 요약 기술 발전을 위해서는 모델 개발 목적에 적합한 검증된 학습데이터가 필수
 - AI가 해당 텍스트를 이해하고 핵심 내용을 요약적으로 전달하기 위해서는 AI SW가 해당 텍스트의 주요 내용이 무엇 인지를 이해할 수 있는 형태로 가공된, 다양한 유형의 대규모 요약 텍스트 데이터 구축이 필요
 - 특정 채널에 편향되지 않는 AI 요약기술 개발을 위해서는 채널별로 균형 있는 데이터 원문 수집과 함께, 텍스트 성격에 따라 핵심내용에 영향을 미치지 않는 부분들에 대한 정제 작업이 필수로 요구됨

2.1.3 머신러닝을 통해 해결이 가능한 문제 상황

- ☐ 현재 우리나라는 AI 요약기술 개발 및 활용을 위한 문서요약 텍스트 데이터의 축적·활용 수준이 미흡한 상황
 - 국내 AI 요약 기술 개발과 관련된 다수의 연구들에서는 해당 텍스트의 제목을 본문의 요약문으로 가정하거나 뉴스 기사의 제목 혹은 첫 문장을 전체 기사의 요약문으로 가정하여 AI 요약 기술을 위한 학습데이터로 활용 중
 - 이러한 조작적 정의는 본문 전체의 핵심 내용이나 의미 전달을 온전히 포함하지 못하는 한계점을 내포함
 - 또한 요약 결과물의 분량을 정해진 어절 수나 문장 수로 제한하거나, 혹은 전체 본문 길이 대비 특정 기준치 이내 분량으로 제한하는 등 본문 내용에 대한 고려와 무관한 분량 제한으로 AI 요약 기술로 생성된 결과물 품질에 근본적인 한계를 갖고 있음

2.1.4 인공지능 데이터를 적용하여 해결하고자 하는 임무

- ☐ 다양한 한국어 원문 데이터로부터 정제된 추출 및 생성 요약문을 도출하여 검증된 한국어 문서 요약 AI 데이터셋 구축 및 배포
 - 한국어 원문 데이터를 확보하는 과정에서 원문과 요약문의 공개 및 재사용에 제한이 없도록 저작권 문제를 완전히 해결한 원천 데이터 확보
 - 뉴스기사, 논문, 특허 등 특정 분야 (domain)로만 구성된 기존 영문 문서 요약 데이터셋과는 다른 원문 데이터의 다양성 추구
- ☐ 구축된 한국어 문서 요약 AI 데이터셋을 기반으로 추출/생성 요약 AI 알고리즘 개발 및 배포
 - 원천데이터와 구축된 문서 요약문 데이터에 대한 탐색적 데이터 분석 (explanatory data analysis, EDA) 예시 (튜토리얼 문서, 분석 코드, 튜토리얼 영상 등) 공개
 - 오픈소스 코드 저장소 (github)를 통한 문서요약 AI 모델 소스코드 공개
- ☐ 추출/생성 요약 AI 알고리즘을 이용한 문서 요약 관련 서비스 구현 및 API 배포
 - 문서요약 AI 모델 기반 서비스의 API 형식 및 레퍼런스 공개

2.2 데이터 구축 유의사항

2.2.1 인공지능 데이터를 구축하여 배포했을 때 발생가능한 위험요소

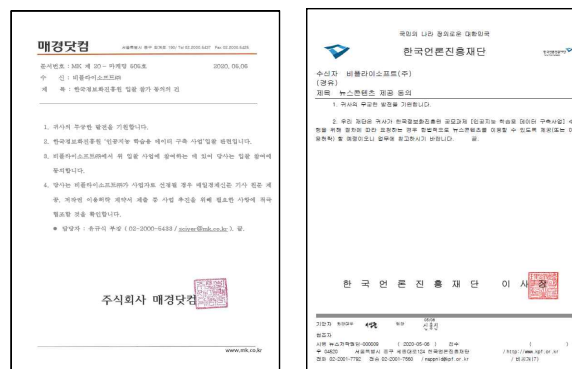
- ☐ 텍스트 데이터의 합법적 사용권에 대한 이슈 발생 가능
 - 인공지능 산업의 발전을 위해서는 자유롭게 수정, 가공, 배포가 가능한 국가 언어의 공공재 역할이 필수적으로 요구되는 바, 국립국어원에서는 신문기사 말뭉치 구축사업을 통해 현재 약 10억 어절의 400만 건 기사가 2차 정제를 거쳐 구축되어 있음
 - 그러나 해당 데이터는 말뭉치 구축 및 활용 목적으로, 산업계 및 학계의 기술개발 및 연구에 활용하기 위함이며, 별도의 콘텐츠 재판매 등 수익사업을 위한 것이 아니기 때문에 원본데이터를 제공 받는 형태에 있어서 한계가 존재함
 - 또한 대상저작물 및 복제·변형물의 이용허락 최소 기간은 계약체결일로부터 2030년 12월 31일까지이며, 권리자 또는 저작자인 언론사가 이용허락 중지 의사를 밝히면 그 의사 내용에 따라 이용허락이 중지될 수 있음

2.2.2 데이터 획득에서 검수과정까지 발생가능한 법적 문제

- ☐ 획득 및 검수까지의 과정에서는 주관기관인 (주)비플라이소프트와 언론매체가 체결한 저작권 협약을 통하여 발생가능한 법적 문제를 배제 가능

2.2.3 문제 발생을 방지 또는 해결하기 위해 실시한 조치

- ☐ 자유롭게 수정, 가공, 배포가 가능한 원문 데이터 확보를 위해 저작권 협약 체결
 - 주관기관인 (주)비플라이소프트는 2002년부터 다양한 뉴스 데이터를 수집하여 데이터베이스로 구축하고 있으며 현재까지 수집된 기사는 약 4억 건 이상으로, 2019년에 생성된 자료만 520만 건 이상임
 - 2006년 6월 언론진흥재단의 '디지털뉴스 저작권 집중관리단체'로 등록되었으며, 뉴스코리아 사업이 본격적으로 시작되면서 비플라이소프트가 핵심파트너 2개 회사 중 하나로 선정되었음



[그림 2] 원문데이터의 확보를 위한 저작권 협약 내용

□ 현재 언론진흥재단을 통해 총 60개 언론매체에 대한 저작권 계약을 체결 완료하였으며, 그 외 4개 매체와 직계약 진행 중

[표 1] 저작권 계약이 완료된 언론매체 리스트

구분	언론사명
전국종합일간	국민일보, 내일신문, 서울신문, 세계일보, 한겨레, 한국일보 (6개)
지역종합일간	강원도민일보, 강원일보, 경기일보, 경남도민일보, 경남신문, 경남일보, 경북도민일보, 경북매일신문, 경북일보, 경상이룸, 경인일보, 광주매일, 광주일보, 국제신문, 기호일보, 남도일보, 대구신문, 대구일보, 대전일보, 동양일보, 매일신문, 무등일보, 부산일보, 새전북신문, 영남일보, 울산매일, 인천일보, 전남일보, 전라일보, 전북도민일보, 전북일보, 제민일보, 제주신보, 중도일보, 중부매일, 중부일보, 충북일보, 충청일보, 충청투데이, 한라일보 (40개)
경제일간	건설경제, 머니투데이, 서울경제, 아시아경제, 아주경제, 이데일리, 이투데이, 파이낸셜뉴스, 한국경제, 헤럴드경제 (10개)
스포츠일간	스포츠서울, 스포츠월드 (2개)
전문일간	전자신문 (1개)
전문주간	농민신문 (1개)

3. 획득·정제

3.1 원시데이터 선정

3.1.1 원시데이터 특성 현황 (구조, 형태, 규모, 저작권 등)

원시데이터 종류	신문	기고문	잡지	법률
자료 형태	PDF 원문 추출 뉴스 텍스트	PDF 원문 추출 칼럼 및 오피니언 텍스트	PDF 원문 추출 및 웹진 기사 텍스트	법원 판결문 뉴스 텍스트 및 전국 법원 주요 판결문 텍스트
자료 규모	30만 건	6만 건	1만 건	3만 건
중요성	기본요약 알고리즘 확보	사실 관계 요약이 아닌 의견 제시 요약 형태	장문 요약 및 문법적 다양성 확보	실용문 핵심 사실관계 추출
확보방안	10개 언론사 저작권 협의 완료			법률뉴스, 법원사이트, 판결문 보도 크롤링

3.2 획득·정제 절차

3.2.1 획득 과정 및 절차

□ 총 40만 건의 원문데이터를 활용하여 80만 건의 AI 학습데이터를 구축하고자 하며, 이용 기간의 제한이 없이 영구적으로 저작권이 확보된 신문기사, 기고문 (사설), 잡지, 그리고 법률 (법원 판결문)으로 이루어진 40만 건의 원문데이터를 확보할 예정임

- 신문기사

- 신문기사는 요약 알고리즘의 핵심적인 데이터로서 10개 언론사로부터 30만건을 획득
- 현재 226종 신문 지면, 67종의 잡지 지면, 2,457종의 온라인 매체로부터 뉴스 텍스트를 수집하여 원문 데이터로 구축하고 있으며, 이 중 종합면 30%, 정치 20%, 경제 20%, 사회 20%, 문화 및 스포츠 기타 10%의 비율로 원문 기사를 확보함

- 기고문

- 기고문은 사실관계의 전달에 중점을 둔 일반적인 뉴스 텍스트와 달리 개별적인 주장을 담고 있는 형태의 문서로서 신문의 오피니언 면을 통해 확보
- 다양한 형태의 주장이 나올 수 있기 때문에 특정 매체에 대한 집중도를 줄이고 정치/경제/사회/문화/과학 등 다양한 주제를 균등하게 배분하여 학습데이터를 구축

- 잡지
 - 잡지의 경우 전문성이 뚜렷하고 텍스트의 길이가 긴 편이므로 1차 학습데이터 구축에 있어서 1만 건 수준으로 제한
 - 시사/경제, 공학/기술, 문화/라이프, 예술/엔터테인먼트, 요리/건강, 취미/레포츠, 컴퓨터/인터넷 등 7개의 카테고리로 구분
- 법률
 - 판결문은 방대한 분량과 만연체적 특성으로 인해 요약에 어려움이 있으므로, 기사를 통해 판결의 요지가 정확히 제시된 뉴스 형태 및 실제 법원이 판결 취지를 요약해서 제공하는 공보성 게시물 (각 법원의 '우리법원의 주요판결과'와 공보판사가 작성한 '보도자료' 등)을 원문으로 수집

소식		우리법원 주요판결			
새소식		전체글수 : 689 건		검색	
우리법원 주요판결		번호	제목	작성일	첨부
보도자료/언론보도해명		689	[민사] 손해배상(의)(청구지)방법원 2017가합202415)	2019.08.26	2380
중요재판일정		688	[행정] 건축이행강제금부과처분취소(2017구합2894)	2019.06.19	1629
포도뉴스		687	[형사] 업무상과실치사 등 [2018노575]	2018.12.11	3379
자료실		686	[형사] 공무집행방해 [2017노1604]	2018.08.22	3424
법원게시판	+	685	[행정] 특정경제범죄가중처벌등에관한법률위반(사기) 등 [2018고합35, 98(병합)]	2018.08.20	2727
E-mail Club		684	[행정] 폐기물처리업 허가취소 처분 취소청구의 소(2018구합2167)	2018.08.17	1927
		683	[민사] 고액부담금 청구(2016가단103316)	2018.07.30	1611
		682	[형사] 통신비밀보호법위반(2018고합92)	2018.07.25	1918
		681	[형사] 공중위생관리법위반 등(계천2018고단78)	2018.07.18	1269
		680	[형사] 공무집행방해(2017고단1453)	2018.06.29	1838

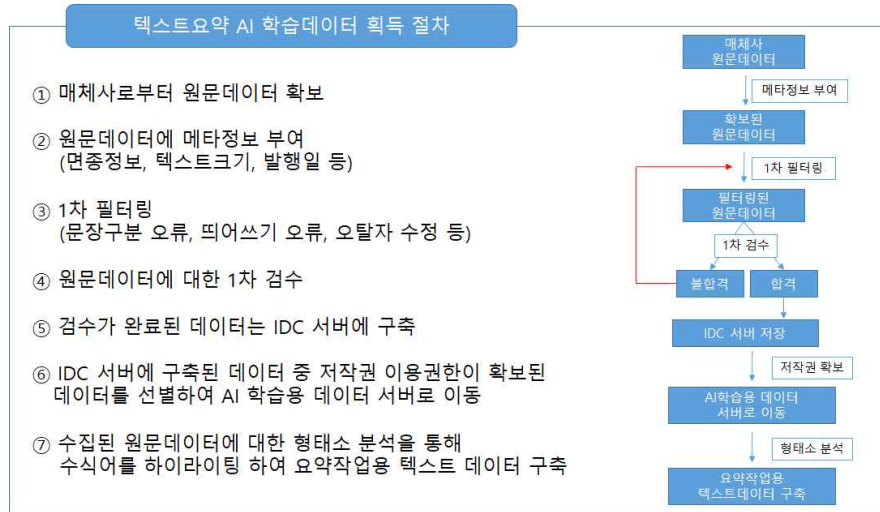
[그림 3] 판결문 데이터 수집 루트

- 이러한 자료들은 공공에 공개되는 자료로서 저작권 활용에 제약이 없음
- 각 법원의 판결 데이터를 전자적으로 크롤링하여 1차 가공 후 개별 로컬 DB에 구축
- 각 판결문마다 해당 법률 조항을 메타정보로 포함시킴으로써 향후 요약 내용 및 판결 차이의 원인 분석 등에 활용

[표 2] 원문데이터 세부 목록

구분	세부 목록
신문기사	IT/과학, 경제, 국제, 기업, 메인 헤드라인, 문화, 부동산, 사회, 스포츠, 연예/오락, 정치, 종합, 지역
기고	일반적인 뉴스 텍스트와 달리 개별적인 주장을 담고 있는 형태의 문서
잡지	전문성이 분명한 시사/경제, 공학/기술, 문화/라이프, 예술/엔터테인먼트, 요리/건강, 취미/레포츠, 컴퓨터/인터넷 등 7개의 카테고리에 대한 잡지 기사
법률	기사를 통해서 판결의 요지가 정확히 제시된 뉴스 형태와 실제 법원이 판결 취지를 요약해서 제공하는 공보성 게시물

3.2.2 원문데이터 획득 절차



[그림 4] 원문데이터 획득 절차

3.2.3 자연어처리

- 사용된 자연어 처리기
 - wigo 문단/문장 구분기
 - mecab + wigo word extract
- 자연어 처리기 활용 과정
 - 공백 특수문자 표준화
 - 문단 구분
 - 문단 안에서 문장 구분
 - 형태소 결과는 mecab을 우선적으로 활용하고 mecab 에서의 unknow 부분은 wigo 단어 추출을 활용
 - 단어 추출 (품사 정보 포함)
 - 단어 위치 정보 생성
 - 사용하지 않을 품사 지정
 - 사용하지 않을 품사에 해당하는 단어 위치 정보 생성하여 불용어 처리
- 가이드 라인
 - 요약에 필요한 문단에서의 문장 구분 결과와 불용어에 대한 위치 정보를 생성함
 - 문단과 문장 구분은 구분을 위한 말뭉치를 활용하며 활용하는 각 말뭉치마다 유효성 검사를 위한 조건을 활용
 - 말뭉치는 한국어 종결어미 특수문자 등
 - 예제:) 하였다, 했다 . ! ? 했다는 유효규칙 뒷 부분이 라고 라면 등이 아닐 때 (.) 의 유효규칙 앞뒤가 숫자가 아닐 때
 - 불용어 위치 생성을 위해서 형태소 결과를 활용한 단어, 품사, 위치 정보를 활용함
 - 품사 태그

실질의미유무	대분류(5언 + 기타)	세종 품사 태그		mecab-ko-dic 품사 태그	
		태그	설명	태그	설명
실질형태소	체언	N N G	일반 명사	NNG	일반 명사
		NNP	고유 명사	NNP	고유 명사
		N N B	의존 명사	NNB	의존 명사
				NNB C	단위를 나타내는 명사
		NR	수사	NR	수사
		NP	대명사	NP	대명사
	용언	VV	동사	VV	동사

		VA	형용사	VA	형용사
		VX	보조 용언	VX	보조 용언
		VCP	긍정 지정사	VCP	긍정 지정사
		VCN	부정 지정사	VCN	부정 지정사
	수식언	MM	관형사	MM	관형사
		M A G	일반 부사	MAG	일반 부사
		MAJ	접속 부사	MAJ	접속 부사
	독립언	IC	감탄사	IC	감탄사
형식형태소	관계언	JKS	주격 조사	JKS	주격 조사
		JKC	보격 조사	JKC	보격 조사
		JKG	관형격 조사	JKG	관형격 조사
		JKO	목적격 조사	JKO	목적격 조사
		JKB	부사격 조사	JKB	부사격 조사
		JKV	호격 조사	JKV	호격 조사
		JKQ	인용격 조사	JKQ	인용격 조사
		JX	보조사	JX	보조사
		JC	접속 조사	JC	접속 조사
	선어말 어미	EP	선어말 어미	EP	선어말 어미
	어말 어미	EF	종결 어미	EF	종결 어미
		EC	연결 어미	EC	연결 어미
		ETN	명사형 전성 어미	ETN	명사형 전성 어미
		ETM	관형형 전성 어미	ETM	관형형 전성 어미
	접두사	XPN	체언 접두사	XPN	체언 접두사
	접미사	XSN	명사 파생 접미사	XSN	명사 파생 접미사
		XSV	동사 파생 접미사	XSV	동사 파생 접미사
		XSA	형용사 파생 접미사	XSA	형용사 파생 접미사
	어근	XR	어근	XR	어근
	부호	SF	마침표, 물음표, 느낌표	SF	마침표, 물음표, 느낌표
		SE	줄임표	SE	줄임표 ...
		SS	따옴표,괄호표,줄표	SSO	여는 괄호 (, [
				SSC	닫는 괄호),]
		SP	쉼표,가운뎃점,콜론,빗금	SC	구분자 , · / :
		SO	붙임표(물결,숨김,빠짐)	SY	
		SW	기타기호 (논리수학기호,화폐기호)		
	한글 이외	SL	외국어	SL	외국어
		SH	한자	SH	한자
		SN	숫자	SN	숫자

- 불용어는 수식언에 해당하는 품사인 관형사, 일반부사, 접속부사로 정의함

3.3 획득·정제 기준

3.3.1 획득·정제 기준

□ 메타정보 부여 및 원시데이터 획득 건수

공통	내용
매체유형	중앙지/경제지/전문지/지역지/잡지 등
매체명	-
카테고리	종합/정치/경제/사회/스포츠/IT·과학 등
발행일	연도/월/일
글자수	소 (70)~1,000) / 중 (1,000~1,500) / 대 (1,500~2,000)
제목	-
데이터별	획득 건수
신문	총 50만 건
기고문	총 8만 건
잡지	총 2만 건
법률	총 5만 건


※ 데이터 정제 및 annotation 과정에서의 loss를 고려하여 본래 원시데이터 획득 목표 수량보다 30~50% 여유 있게 확보 예정

3.3.2 획득·정제 전/후 예시

제목		추출 요약
국민은행, `청소년의 멘토 KB 공부방` 700호 전달		
매체유형	경제지	
매체명	매일경제	
카테고리	경제	
기사크기	소(705자)	
발행일	2019.02.18	
원문		생성요약
KB국민은행은 서울 성동구 성수동에서 구세군자선냄비본부와 함께 `청소년의 멘토 KB 공부방` 700호 전달식을 가졌다고 18일 밝혔다. 청소년의 멘토 KB 공부방 조성은 소외계층 청소년들이 자신만의 공간에서 꿈과 희망을 키울 수 있도록 맞춤형 공간을 조성해 주는 사업이다. 지난 2012년부터 올해 1월까지 총 700가구에 공부방을 지원했으며, 올해 100가구를 추가로 지원할 예정이다. 이번 700호에 선정된 가정은 낡은 연립주택의 10평 남짓한 작은 공간에 아버지와 자매 등 총 3명의 가족이 함께 생활하고 있다. 오래된 책상과 의자, 곰팡이로 가득한 벽지에, 세면대조차 없는 화장실에는 변기마저 파손돼 정상적인 이용이 어려운 열악한 환경이었다. 이에 KB국민은행은 공부방 조성이 아닌 실내 인테리어 전반에 대한 대규모 공사를 진행했다. 도배, 장판, 창호, 싱크대 교체, 화장실 개·보수 등의 생활공간 개선 및 책상, 의자, 옷장 등 친환경 원목가구와 학습에 필요한 컴퓨터, 스탠드 등의 물품이 제공돼 쾌적한 공간으로 재탄생 했다.		
전처리 후		
KB국민은행은 서울 성동구 성수동에서 구세군자선냄비본부와 함께 `청소년의 멘토 KB 공부방` 700호 전달식을 가졌다고 18일 밝혔다. 청소년의 멘토 KB 공부방 조성은 소외계층 청소년들이 자신만의 공간에서 꿈과 희망을 키울 수 있도록 맞춤형 공간을 조성해 주는 사업이다. 지난 2012년부터 올해 1월까지 총 700가구에 공부방을 지원했으며, 올해 100가구를 추가로 지원할 예정이다. 이번 700호에 선정된 가정은 낡은 연립주택의 10평 남짓한 작은 공간에 아버지와 자매 등 총 3명의 가족이 함께 생활하고 있다. 오래된 책상과 의자, 곰팡이로 가득한 벽지에, 세면대조차 없는 화장실에는 변기마저 파손돼 정상적인 이용이 어려운 열악한 환경이었다. 이에 KB국민은행은 공부방 조성이 아닌 실내 인테리어 전반에 대한 대 규모 공사를 진행했다. 도배, 장판, 창호, 싱크대 교체, 화장실 개·보수 등의 생활공간 개선 및 책상, 의자, 옷장 등 친환경 원목가구와 학습에 필요한 컴퓨터, 스탠드 등의 물품이 제공돼 쾌적한 공간으로 재탄생 했다.		

3.4 획득·정제 조직


- 데이터 획득은 주관기관인 (주)비플라이소프트 내 R&D 연구소의 크롤링팀에서 전담함
 - 크롤링팀 내에 크롤러 프로그램 개발/운영 조직
 - 매체별 획득 데이터 중 본문과 기정의된 1차 메타데이터 (기사발행일, 제목 등)까지 1차 가공
- 획득된 데이터의 정제는 주관기관인 (주)비플라이소프트 내 미디어 빅데이터 센터에서 전담함
 - 1차 가공된 본문과 추가 메타데이터 식별 등의 정제작업을 수행함
 - 데이터 중 광고 등 본문 외 데이터를 식별 및 정제
- 정제절차 표준화 및 훈련
 - 정제 작업 절차 가이드 작성 및 교육
 - 매체별 정제작업 전 원문데이터와 정제작업 후 가공데이터 사례 교육



[그림 5] 데이터 획득·정제 조직

3.5 획득·정제 도구

- 주관기관인 (주)비플라이소프트에서 자체 개발한 DOM Parser 및 Meta Extractor를 활용하여 데이터를 획득 및 정제함
 - 1차로 매체별 DOM 구조로 구분된 DOM Parser를 통해 HTML 데이터 1차 가공
 - 매체별로 기사 콘텐츠를 구성하는 HTML-DOM 구조가 상이함
 - Meta Extractor를 통해 기정의된 메타정보를 추출
 - 상이한 DOM 구조에서 정의된 메타정보를 Mapping하여 추출
 - 추출된 데이터를 기사 Database에 저장



• 매체별로 기사 콘텐츠를 구성하는 HTML-DOM 구조가 상이함
• 상이한 DOM 구조에서 정의된 메타 정보 Mapping하여 추출

[그림 6] 데이터 획득·정제 도구

3.6 데이터 전처리

3.6.1 전처리 기준

☐ 문장 분리

- (주)위고에서 자체적으로 개발한 NLP 부분 문장분리 기술을 활용하여 문장을 분리하여 3줄 요약시 활용
 - 분리된 문장은 한 줄씩 개행하여 어노테이터들이 한 문장을 구분하는 데에 도움을 줌

□ 문장구분 오류

- 원문의 문장 기호가 존재하지 않거나 잘못 사용된 경우 문장 자체를 분리하는 것부터 문제가 발생하며, 이는 이후 추출 및 생성 요약문을 선정·작성하는 것을 어렵게 하는 요인으로 작용할 가능성이 높음
- 본 과제에서는 오픈소스 문장 분리기 (Koala NLP)와 참여기관 (WIGO)이 자체 보유한 한국어 어휘사전 기반 문장 분리기를 결합하여 99% 이상 정확도를 갖는 문장 분리 수행 예정

☐ 띄어쓰기 오류

- 웹페이지에 저장된 문서를 수집할 때 HTML 문법을 제거하는 과정에서 단어나 문장의 띄어쓰기 오류가 발생하는 상황이 빈번히 발생하며, 이는 형태소 분석을 통한 불필요한 단어 제거를 어렵게 하는 요인으로 작용할 수 있음
- 참여기관 자체 보유 한국어 어휘사전을 활용하여 두 단어가 띄어쓰기 오류로 결합된 것으로 판단되면 이를 두 단어로 분리
- 예 : 문장분리기성능을검증한결과 → 문장 분리기 성능을 검증한 결과

☐ 오탈자 수정

- 웹페이지에 게시된 형태의 원문일 경우 오탈자의 비율이 상대적으로 높으며, 이는 이후 과정에서의 형태소분석 및 문서요약 과정에서 요약문의 품질을 저하시키는 요인이 될 수 있음
- 참여기관이 자체 보유한 한국어 어휘사전을 활용하여 초성-중성-종성 간의 관계를 고려하여 오탈자 판단 및 수정

☐ 문장 속 수식어 하이라이팅

- 기 보유하고 있는 통합사전과 추가로 보완할 도메인 사전을 바탕으로 형태소 분석을 통해 품사를 구분함
 - 하이라이팅 된 수식어는 어노테이터들이 3줄 요약시 주요 내용을 파악하는 데에 방해되는 수식어를 쉽게 구분할 수 있도록 도움을 줌



[그림 7] 원문문서 전처리 과정

3.6.2 전처리 도구


- (주)위고에서 개발한 자체 AI프레임워크
 - WIGO AI Platform (NLP 엔진 사용)



[그림 8] 데이터 전처리 도구

3.6.3 전처리 조직

- 사전관리는 (주)위고의 서비스개발팀 인력이 전담함
 - 기 통합 구축된 사전 정리
 - 신조어 관리를 통해서 새로운 단어를 계속적으로 업데이트
- 문장 분리 및 수식어 구분은 AILAB실 인력이 전담함
 - 문장 분리기 정확도 향상을 위한 작업
 - 형태소 분석을 통한 수식어 제거
- 연계 기관과의 인터페이스는 서비스개발팀 인력이 전담함
 - 원문데이터 인터페이스
 - 전처리 완료한 데이터 인터페이스



[그림 9] 데이터 전처리 조직

4. 어노테이션/라벨링

4.1 어노테이션/라벨링 절차

□ 문서요약 텍스트 AI 데이터셋 구축을 위한 어노테이션 절차는 아래 표와 같음

절차	주요내용
전처리데이터(입력)	수집 및 정제 후 전처리된 원천데이터(문서 형태)를 가공 도구를 통해 제공
가이드라인 확인	가공 기준 및 검수 기준으로 활용되는 문서요약 가이드라인 확인
정제된 문서의 사전 정보 확인	수집 및 정제, 전처리 과정에서 생성된 문서 정보(카테고리, 글자 수 등)를 확인
핵심 키워드 선정	제목 등 사전 정보를 통해 핵심 키워드 확인
정제된 문서 정독	제공된 전처리 후 원천데이터 확인
문장 선정	5문장 내외의 중요 문장 확인
주요문장 선정 (가공 1단계)	선정된 중요 문장 중 3문장 선택
3문장 추출 요약문 생성 (가공 산출물 1)	원문 데이터 내 중요도에 따라 순차적으로 입력
생성요약문 작성을 위한 어군 선택	원문 데이터에서 확인 주요 내용을 함축적으로 표현할 수 있는 단어들 선택 (집단화, 추상화, 유의어)
선정된 어군 내 선택 (가공 2단계)	원문 데이터에서 수정 불가 어군 및 수정 가능 어군을 선택한 후, 수정 가능 어군을 수정
생성요약문 생성 (가공 산출물 2)	생성 요약문 입력

□ 가공 절차에 대한 입력물/산출물의 예시는 아래 표와 같음 아래 표와 같음

	구분	예시
입력물	정제된 문서	수도가 헛갈리는 나라 중 하나인 캐나다. 잠시 머뭇거렸다면? 오타와가 정답이다. ... (중략)... 서쪽의 오대호와 동쪽의 세인트로렌스 강 중간에 위치한 오타와는 물길을 따라 유럽 대륙에 비버 모피와 오크 목재를 수출한 역사가 있다. 오타와의 랜드마크를 꼽는다면 신고딕 양식으로 지어진 국회의사당과 리도 운하다. 둘은 위치상 맞붙어 있어 이 주변은 늘 관광객으로 북적거린다. 리도 운하는 오타와 시내 중심부에서 시작해 킹스턴 온타리오 호수까지 202km나 이어진다. 영국의 지배를 받던 시절, 미국의 침략에 대비하기 위해 군사 물자를 실어 나르는 통로로 건설된 리도 운하는 1826년부터 공사를 시작해 6년 후 완공됐다. 전쟁에 한 번도 사용된 적은 없지만 운하가 생기면서 교통의 중심으로 떠오른 오타와는 비약적으로 발전했다. 리도 운하는 19세기 초 아메리카 대륙의 역사와 건설 기술을 담은 사례로 가치를 인정받아 2007년 유네스코 세계문화유산에 등재됐다. ... (이하 생략)
	추출요약	오타와의 랜드마크를 꼽는다면 신고딕 양식으로 지어진 국회의사당과 리도 운하다. 리도 운하는 오타와 시내 중심부에서 시작해 킹스턴 온타리오 호수까지 202km나 이어진다. 리도 운하는 19세기 초 아메리카 대륙의 역사와 건설 기술을 담은 사례로 가치를 인정받아 2007년 유네스코 세계문화유산에 등재됐다.
산출물	생성요약	오타와 시내 중심부에서 202km나 연결된 오타와의 랜드마크인 리도 운하는 19세기 초 아메리카 대륙의 역사와 건설 기술을 담은 사례로 가치를 인정받아 2007년 유네스코 세계문화유산에 등재됐다.

4.2 어노테이션/라벨링 기준

4.2.1 어노테이션/라벨링 대상

□ 문서요약 텍스트 AI 데이터셋 구축을 위한 가공 종류 및 대상은 아래 표와 같음

가공 종류	설명	가공 도구
추출요약	원문을 포괄적으로 설명할 수 있는 3개의 문장을 선택하여 본문을 요약할 수 있는 추출요약 문장 추출 - 3문장의 입력 순서는 중요도 순서대로 입력함을 원칙으로 함	클라우드 소싱 플랫폼
생성요약	원문내용과 논조를 유지하면서, 원문에서 활용되지 않는 단어 및 표현을 활용한 1개의 생성요약 문장 생성	
가공문 구분	가공문 세부구분	가공 수량
신문기사	IT/과학, 경제, 국제, 기업, 메인 헤드라인, 문화, 부동산, 사회, 스포츠, 연예/오락, 정치, 종합, 지역	300,000
기고	일반적인 뉴스 텍스트와 달리 개별적인 주장을 담고 있는 형태의 문서	60,000
잡지	전문성이 분명한 시사/경제, 공학/기술, 문화/라이프, 예술/엔터테인먼트, 요리/건강, 취미/레포츠, 컴퓨터/인터넷 등 7개의 카테고리에 대한 잡지 기사	10,000
법률	기자를 통해서 판결의 요지가 정확히 제시된 뉴스 형태와 실제 법원이 판결 취지를 요약해서 제공하는 공보성 게시글	30,000

4.2.2 추출요약의 어노테이션/라벨링 기준

□ 추출요약은 가공 대상에 정의되어 있는 모든 가공문을 추출요약함을 원칙으로 함

- 메타데이터 확인 : 가공도구에서 제공되는 원문에 대한 정보 (메타데이터)를 확인하며, 메타 데이터의 종류는 아래와 같음

종류	설명
문서번호	전체 문서 중 제공된 문서의 고유 ID
매체	중앙지/지방지/경제지
매체권역	중앙/지방/특수지
문서유형	온라인/오프라인
문서카테고리	기사의 유형 정보 제공
본문 글자수	본문의 길이 확인
제목	기사의 제목으로 키워드 확인 가능

- 키워드 확인 : 제공된 문서의 제목을 통해 키워드를 확인하며, 키워드는 고유명사 (이름, 지명)를 먼저 선택한 뒤 이후에 관련된 동사를 확인함

- 작업 효율성을 높이기 위해 가공자의 선택 사항으로 개체명 인식 기술을 활용하도록 가이드라인 작성
- 공지문을 통해 제목 및 문서에서 반복되는 키워드를 반드시 확인하도록 유도하고 키워드가 포함된 문장을 시각화하도록 작업 편의성을 부여

- 원문 정독 : 기사의 구조를 파악하고 키워드가 포함된 문장 (리드문)을 찾되, 기사의 구조 형태는 아래와 같음

종류	설명
역피라미드 (두괄식) 구조	키워드가 포함된 문장이 원문의 앞부분에 포함된 경우
피라미드 (미괄식) 구조	키워드가 포함된 문장이 원문의 뒷부분에 포함된 경우
병렬 (나열식) 구조	키워드가 다양하며 원문 전체에 나열된 경우

- 추출요약문 작성 : 형태적 구조를 바탕으로 원문의 내용을 잘 표현하는 문장 3개 (리드문 포함)를 추출하여 우선순위에 따라 차례로 작성함

구분	원문	추출요약 결과물
좋은 예	‘그것이 알고 싶다’ 버닝썬 편이 방송된 뒤 린사모와 연관성을 의심받은 지창욱과 제작진 측이 해명했다. (사실) 지난 23일 방송된 SBS 시사 교양 프로그램 ‘그것이 알고 싶다’에서는 버닝썬을 둘러싼 논란들을 조명했다. 이 가운데 버닝썬의 지분 20%를 가진 투자자 대만 린사모와 지창욱이 함께 찍은 사진이 공개됐다. 이에 지창욱이 버닝썬과 관련된 것이 아니냐는 의혹이 불거졌다. 이에 지창욱의 소속사 클로리어스 엔터테인먼트 측은 24일 “‘그것이 알고 싶다’ 방송에 노출된 이미지 속 인물과 당사 배우는 전혀 관계없으며 팬이라며 부탁한 요청에 응해준 사진임을 알려드립니다”고 해명했다. (사실) 이어 “배우에 대한 허위사실이 무분별하게 확대, 악성 루머 및 성희롱 등으로 이어져 배우의 명예가 심각하게 훼손되는 상황”이라며 “위 내용과 관련한 추측성 루머에 대한 작성, 게시, 유포 등의 불법 행위를 자제해주시기 바란다”며 법적 대응을 예고했다. ‘그것이 알고 싶다’ 측 역시 이날 “지창욱 사진은 린사모에 대해 설명하기 위한 장치였다”며 “지창욱이 버닝썬 게이트와 관련있다는 내용이 아니었다”면서 “린사모가 한국 연예계에 많은 친분을 갖고 있다는 걸 드러내기 위해 공인인 스타들과의 사진을 사용했고 방송에서도 이를 반영했다”고 해명했다. (사실) 지창욱 측과 ‘그것이 알고 싶다’ 측 모두 해명을 했으나 여전히 지창욱과 린사모의 관련성을 의심하는 누리꾼이 많은 상황이다. 이에 ‘그것이 알고 싶다’ 시청자 게시판에는 지창욱에 대한 사과 방송을 하라는 요구가 빗발치고 있다. 한편, 지창욱은 지난 2017년 입대해 백골 부대에서 군 복무 중이며 오는 4월 전역할 예정이다.	1. ‘그것이 알고 싶다’ 버닝썬 편이 방송된 뒤 린사모와 연관성을 의심받은 지창욱과 제작진 측이 해명했다. 2. 이에 지창욱의 소속사 클로리어스 엔터테인먼트 측은 24일 “‘그것이 알고 싶다’ 방송에 노출된 이미지 속 인물과 당사 배우는 전혀 관계없으며 팬이라며 부탁한 요청에 응해준 사진임을 알려드립니다”고 해명했다. 3. ‘그것이 알고 싶다’ 측 역시 이날 “지창욱 사진은 린사모에 대해 설명하기 위한 장치였다”며 “지창욱이 버닝썬 게이트와 관련있다는 내용이 아니었다”면서 “린사모가 한국 연예계에 많은 친분을 갖고 있다는 걸 드러내기 위해 공인인 스타들과의 사진을 사용했고 방송에서도 이를 반영했다”고 해명했다
설명	1. 추출요약된 문장은 서로 다른 내용 (사실)을 담고 있음 2. 리드문에 ‘지창욱과 제작진 측이 해명’한 사실이 포함되어 있으므로, 뒤에 나오는 해명의 구체적인 내용은 별도로 추출하지 않음	
나쁜 예	양도세 감소에 유류세 감면 등 영향 관리재정수지 36조 적자 역대 최대 올 들어 5월까지 누적 국세 수입이 지난해 같은 기간보다 1조 2000억원 가량 줄어든 것으로 나타났다. 지난 4년간 지속된 ‘세수 호황’이 막을 내리는 모습이다. 9일 기획재정부가 내놓은 ‘월간 재정동향 2019년 7월호’에 따르면 올해 1~5월 중 국세 수입은 139조 5000억원으로 1년 전보다 1조 2000억원 감소했다고 밝혔다. 누적 국세 수입은 지난 2월부터 4개월 연속 감소하고 있다. 세목별로 보면 소득세(근로·종합·양도소득세) 수입이 37조 5000억원으로 지난해 같은 기간보다 2000억원 감소했고, 부가가치세는 1.2% 줄어든 32조원이 걸렸다. 법인세수는 40조 1000억원으로 1년 전보다 2조 1000억원 늘었다. 전체 세수가 감소한 이유는 부동산 거래 감소로 양도소득세 수입이 줄었고, 부가가치세 중 지방소비세로 이관하는 비율이 늘어난 데다 유류세 감세 정책까지 겹쳤기 때문으로 풀이된다. 5월 한 달만 놓고 보면 국세 수입 규모는 30조 2000억원으로 1년 전보다 7000억원 줄었다. 예산 기준 세수진도율은 지난해 5월보다 5.1% 포인트 떨어진 47.3%로 나타났다. 세수진도율은 1년간 건어야 할 세금 대비 특정 기간에 실제 걷은 세금의 비율을 의미한다. 1~5월 통합 재정수지는 약 19조 1000억원 적자로 추정되고, 통합재정수지에서 4대 보장성 기금을 뺀 정부의 실제 재정 상태를 나타내는 관리재정수지는 36조 5000억원 적자였다. 5월까지 통합재정수지와 관리재정수지 적자 규모는 관련 통계 집계를 시작한 2011년 이후 가장 컸다. 세종 하중훈 기자 artg@seoul.co.kr	1. 양도세 감소에 유류세 감면 등 영향 관리재정수지 36조 적자 역대 최대 올 들어 5월까지 누적 국세 수입이 지난해 같은 기간보다 1조 2000억원가량 줄어든 것으로 나타났다. 2. 지난 4년간 지속된 ‘세수 호황’이 막을 내리는 모습이다. 3. 9일 기획재정부가 내놓은 ‘월간 재정동향 2019년 7월호’에 따르면 올해 1~5월 중 국세 수입은 139조 5000억원으로 1년 전보다 1조 2000억원 감소했다고 밝혔다. 4. 누적 국세 수입은 지난 2월부터 4개월 연속 감소하고 있다.
설명	1. 추출요약은 3문장을 추출해야 하나 4문장을 추출하였음 2. 문장의 우선순위에 따라 내용을 추출해야 하나 우선순위를 무시하고 기사 내용의 흐름순으로 추출	

4.2.3 생성요약의 어노테이션/라벨링 기준

□ 생성요약은 가공 대상에 정의되어 있는 모든 가공문을 생성요약함을 원칙으로 함

- 메타데이터 확인 : 가공도구에서 제공되는 원문에 대한 정보 (메타데이터)를 확인하며, 메타 데이터의 종류는 아래와 같음

종류	설명
기사번호	전체 문서 중 제공된 문서의 고유 ID
매체	중앙지/지방지/경제지
매체권역	중앙/지방/특수지
문서유형	온라인/오프라인
문서카테고리	기사의 유형 정보 제공
본문 글자수	본문의 길이 확인
제목	기사의 제목으로 키워드 확인 가능

- 키워드 확인 : 제공된 문서의 제목을 통해 키워드를 확인하며, 키워드는 고유명사 (이름, 지명)를 먼저 선택한 뒤 이후에 관련된 동사를 확인함

- 원문 정독 : 기사의 구조를 파악하고 키워드가 포함된 문장 (리드문)을 찾되, 기사의 구조 형태는 아래와 같음

종류	설명
역피라미드 (두괄식) 구조	키워드가 포함된 문장이 원문의 앞부분에 포함된 경우
피라미드 (미괄식) 구조	키워드가 포함된 문장이 원문의 뒷부분에 포함된 경우
병렬 (나열식) 구조	키워드가 다양하며 원문 전체에 나열된 경우

- 생성요약문 작성

- 생성요약은 추출요약으로 형성된 문장, 제목의 키워드, 동의어 등을 활용하여 기사의 내용을 한 문장으로 요약함을 원칙으로 함
- 원문 내 육하원칙의 내용이 모두 포함되어야 함
- 기술할 때 함축을 위해 1) 집단화, 2) 추상화, 3) 동의어 등을 활용함
 - ※ 집단화 : 원문에 포함된 다양한 객체 등을 하나의 그룹으로 묶어 집단을 대표하여 요약하는 것을 의미함
 - 추상화 : 원문에 포함된 구체적 내용을 대표할 수 있는 개념으로 치환하여 수정하는 것을 의미함
 - 동의어 변환 : 글의 내용 변화를 최소화하면서 같은 의미의 단어로 수정하는 것을 의미함
- 요약은 원문 글자수의 10% 내외로 함을 원칙으로 함

구분	추출된 주요 문장	생성요약 결과물
좋은 예	윤석열 검찰총장 후보자에 대한 어제 국회 인사청문회는 여야 신경전만 요란했지 검찰총장으로서의 자질 검증은 부실한 정치 공방전이었다. (사실) 여당은 덮어 놓고 후보자를 보호하려고만 하고, 야당은 증거 자료 하나 없이 아님 말고식 공격으로 일관한 청문 행태에 너무나 식상했다는 비판이 쏟아진 까닭이다. (주관적 해석 ©) 정권 눈치를 살피지 않고 검찰 조직의 체질을 과감히 바꾸는 '처음 보는 강골 총장'이기를 기대한다. (행동제시)	윤석열 검찰총장 후보자에 대한 어제 국회 인사청문회(사실)는 검찰개혁에 대한 자질 검증이 없는 식상한 여야 다툼에 그쳤지만, (주관적 해석 ©) 윤석열 후보자는 검찰조직을 개혁하는 과감한 리더십을 보여야 할 것이다. (행동제시)
설명	1. 추출된 주요 문장의 모든 요소 (사실, 주관적 해석, 행동제시)가 생성요약에 모두 포함됨 2. 공방전, 신경전 → 다툼 / 체질을 과감히 바꾸는 → 개혁하는 / 강골 총장 → 리더십 등 기존 단어를 동의어로 변경하였음 3. '국회 인사청문회', '윤석열 검찰총장 후보자', '검찰 개혁' 등 정확한 표현을 사용함 4. '~해야 할 것이다'와 같이 해당 글이 오피니언임을 판별할 수 있는 어미를 사용함 5. '여야' 등 그 의미가 훼손되지 않는 줄임말을 사용	

나쁜 예	윤석열 검찰총장 후보자에 대한 어제 국회 인사청문회는 여야 신 경전만 요란했지 검찰총장으로서의 자질 검증은 부실한 정치 공방 전이었다. (사실) 여당은 덮어 놓고 후보자를 보호하려고만 하고, 야당은 증거 자료 하나 없이 아님 말고식 공격으로 일관한 청문 행태에 너무나 식상했다는 비판이 쏟아진 까닭이다. (주관적 해석 ©) 정권 눈치를 살피지 않고 검찰 조직의 체질을 과감히 바꾸는 '처음 보는 강골 총장'이기를 기대한다. (행동제시)	윤석열 후보자에 대한 어제 국회 인사청문 회(사실)는 검찰개혁에 대한 자질 검증이 없는 부실한 정치공방전이다. (주관적 해석 ©)
설명	1. 100자 내외의 분량이 허락하는데도 '행동제시' 부분을 생성요약에 포함시키지 않음 2. 동의어 변경을 하지 않고 '부실한 정치공방전' 등 원문의 단어를 모두 그대로 사용 3. '윤석열 검찰총장 후보자'가 아닌 '윤석열 후보자'를 사용하는 등 모호한 표현을 사용함 4. '~이다'로 문장을 끝내 해당 글이 오피니언임을 판별할 수 있는 어미를 사용하지 않음	

4.3 어노테이션/라벨링 조직

- 어노테이션/라벨링 조직은 크게 데이터 가공, 클라우드 소싱, 기술지원, 전문가 자문으로 이루어짐
- 데이터 가공 : 프로젝트 운영/관리 및 클라우드 소싱 인력을 관리하고 가공 가이드라인 작성 및 운영을 담당함
 - 클라우드 소싱 : 원문에 대한 문서요약 가공 (추출요약/생성요약/원문 품질평가) 작업을 진행함
 - 기술지원 : 가공/검수 도구를 개발 및 운영하고 클라우드 소싱 플랫폼 (aiworks)을 운영함
 - 전문가 자문 : 문서 요약 가공 업무 전반에 걸쳐 자문을 담당함




[그림 10] 어노테이션/라벨링 조직

4.4 어노테이션/라벨링 도구

4.4.1 도구 개요

- 문서요약 텍스트 AI 데이터셋 제작 도구는 MIT License로 배포된 데이터 가공 도구를 커스터마이징한 어노테이션 도구임
- 사업종료 후 도구를 공개해 다양한 데이터 가공작업에 활용될 수 있도록 한글화 작업 및 텍스트 데이터에 대한 가공 기능 등을 추가 구현함
 - 가공자의 편의를 위하여 UI/UX는 추후 변경될 수 있음
- 개발한 어노테이션 도구는 ㈜테스트웍스가 보유한 데이터 수집/가공 플랫폼인 aiworks와 연동하여 배포 예정



[그림 11] 학습용 데이터 제작 도구 실행 화면

4.4.2 주요 도구 기능

□ 2가지 형식의 어노테이션

- 가공하고자 하는 원문을 추출요약 (Sequence Labeling) 형식, 생성요약 (Sequence To Sequence) 형식의 2가지 형식으로 분류하여 정의된 요약 방식에 따라 어노테이션이 가능함

추출요약 (Sequence Labeling) 형식	생성요약 (Sequence-to-Sequence) 형식

- 추출요약 도구기능 : 지문 내 의미 있는 구/절/문장 등 특정 범주에 대해 Labeling 하는 기법으로, 문서요약 과제에서는 지문 내 문장의 중요도에 따라 3개의 문장을 추출하여 Labeling을 진행함
- 생성요약 도구기능 : 하나의 범주 (지문)에 대하여 새로운 범주 (문장)으로 set을 이뤄 annotation하는 기법으로서, 문서요약 과제에서는 지문에서 추출한 3개의 문장을 기반으로 1개의 새로운 문장을 만들으로써 annotation을 진행함

□ 원문 품질평가

- 가공하고자 하는 원문에 대해 4가지 항목에 대한 평가 (Rating)를 함으로써 원문 품질에 대한 어노테이션이 가능함
- 원문 품질평가 기능은 일부 문서에 한해 사용할 수 있으며 평가항목은 추후 변경될 수 있음

평가(Rating) 기능	

5. 검수

5.1 검수 절차

□ 문서요약 텍스트 AI 데이터셋을 구축하기 위한 검수절차는 아래 표와 같음

설명	입력물	산출물	비고
검수Ⅰ	추출요약, 생성요약	1차 검수완료된 추출요약, 1차 검수완료된 생성요약	검수에서 불합격된 추출/생성요약의 경우 가공 작업자가 재작업
검수Ⅱ	1차 검수완료된 생성요약	교차 검수완료된 생성요약	추상성이 높은 생성 요약문에 대해 출수 인원의 교차 검수를 진행함
검수Ⅲ	1차 검수완료된 추출요약, 교차 검수완료된 생성요약	최종 검수완료된 추출요약, 최종 검수완료된 생성요약	-

5.2 검수 기준

- 원문 내 육하원칙의 요소가 모두 있는 경우네는 생성요약문도 육하원칙의 요소를 모두 포함하였는지 기준으로 검수 진행
- 생성요약문의 경우 지문 내 중요도에 따라 추출된 3개의 문장을 기반으로 생성된 문장이므로, 내용적 측면에서 생성 요약문이 문서 전체 내용을 얼마나 커버하는지에 대한 정량적 수치화가 어려움
- 검수 기준은 가공시 사용한 가이드라인 준수 여부를 중심으로 확인함
- 추출요약 : 중요 문장에 대한 추출 여부를 5점 척도를 활용하여 4점 이상을 합격점수로 활용함
 - 생성요약 : 추상적인 내용이 포함되어 있어 질적 요소를 포함하는 5점 척도를 활용하여 4점 이상을 합격 점수로 활용함

검수 기준	추출요약	생성요약
키워드의 활용	제목에서 제시된 주요 단어가 포함된 문장 선택 여부	제목에서 제시된 주요 단어의 활용 여부
리드문의 활용	가장 중요하게 선택된 문장의 구성 형태 확인	가장 중요하게 선택된 문장 활용 여부
6하원칙 내용의 포함	6하원칙 내용이 포괄된 문장의 선택 여부	생성된 문장에서 6하원칙 내용의 포함 정도
주관적 문장의 포함	주관적 문장 수정 불가	-
의미의 중복	선택된 3개 문장 중 중복된 내용의 수준 - 극단적 중복을 회피	-
구체적 문장의 활용	3개 문장 중 1문장은 구체적 문장이 포함되어야 함	구체적 문장의 수정 여부
문장의 추출	문장 변형 금지	문장 원형 추출 금지
추상화, 집단화, 동의어의 선택	-	문장 수정시 추상화, 집단화, 동의 선택의 정도를 질적으로 판단
비문, 미완성 문장	-	비문, 미완성 문장은 반드시 2점 이하로 입력
문장의 길이	-	전체 문장의 10% 내외로 요약 - 극단적 축약, 극단적인 복문은 요약 실패로 판정

- 특히 생성요약의 5점 척도 기준은 아래와 같음

기준(숫자가 높을수록 우선적으로 판단)	점수
1. 문장 구성 : 생성요약문이 비문 2. 문장의 완결성 : 오탈자, 띄어쓰기 오류 등이 문장의 50%를 넘는 경우 3. 핵심 키워드 : 생성요약문에 포함되지 않은 경우 4. 요약의 포괄성 : 생성요약문이 글의 일부만 요약하는 경우 5. 동의어 치환 : 고려대상 아님	1점
1. 문장 구성 : 생성요약문이 비문 2. 문장의 완결성 : 오탈자, 띄어쓰기 오류 등이 3건 이상 발견되는 경우 3. 핵심 키워드 : 생성요약문에 키워드가 포함되지 않은 경우 4. 요약의 포괄성 : 생성요약문이 글의 전체를 요약하는 경우 5. 동의어 치환 : 고려사항 아님	2점
1. 문장 구성 : 생성요약문이 정문 2. 문장의 완결성 : 오탈자, 띄어쓰기 오류 등이 3건 이상 발견되는 경우 3. 핵심 키워드 : 생성요약문에 키워드가 포함된 경우 4. 요약의 포괄성 : 생성요약문이 글의 전체를 요약하는 경우 5. 동의어 치환 : 고려사항 아님	3점
1. 문장 구성 : 생성요약문이 정문 2. 문장의 완결성 : 오탈자, 띄어쓰기 오류 등이 발견되지 않음 3. 핵심 키워드 : 생성요약문에 키워드가 포함된 경우 4. 요약의 포괄성 : 생성요약문이 글의 전체를 요약하고 5. 동의어 치환 : 동의어 치환 1번 포함	4점
1. 문장 구성 : 생성요약문이 정문 2. 문장의 완결성 : 오탈자, 띄어쓰기 오류 등이 발견되지 않음 3. 핵심 키워드 : 생성요약문에 키워드가 포함된 경우 4. 요약의 포괄성 : 생성요약문이 글의 전체를 요약하고 5. 동의어 치환 : 동의어 치환 2번 이상 포함	5점

□ 원문과 요약문의 사실관계가 잘못된 경우 불합격 처리함

5.3 검수 조직

□ 검수 조직은 크게 데이터 검수, 기술지원, 전문가 자문으로 이루어짐


- 데이터 검수 : 검수 전문 인력을 관리하고 검수 가이드라인 작성 및 운영을 담당함
- 데이터 검수 (airworks, 검수 전문가 인력) : 원문에 대한 문서요약 검수 (추출요약/생성요약) 작업을 진행함
- 기술지원 : 가공/검수 도구를 개발 및 운영하고 클라우드 소싱 플랫폼 (airworks)을 운영함
- 전문가 자문 : 문서 요약 검수 업무 전반에 걸쳐 자문을 담당함



[그림 12] 검수 조직

5.4 검수 도구

- 문서요약 텍스트 AI 데이터셋 검수 도구는 문서요약 텍스트 AI 데이터셋 제작도구와 동일함
 - 단 가공한 결과물에 대해 복수 검수 인원이 LiKert 척도 방식을 활용하여 평가 (Rating) 할 수 있는 기능이 포함되어 있음
 - 가공자의 편의를 위하여 UI/UX는 변경될 수 있음



[그림 13] 학습용 데이터 검수 도구 실행 화면

5.5 기타 품질관리 활동

- 지속적인 작업공지문 수정 및 활용
 - 가공 공지문을 기준으로 세부 내용이 포함된 검수 기준을 공유하고 있으며, 검수에서 통과되지 못한 사례를 공유하여 통일된 검수 기준 적용 여부를 지속적으로 확인
 - 월 2회 가공 결과를 컨소시엄 전체에 공유하고 인공지능 개발 뿐만 아니라 가공 오류를 컨소시엄 전체에서 확인하고 작업 공지문을 지속적으로 수정
 - 수정된 작업공지문은 빠르게 업데이트 하여 작업의 연속성 및 정확성을 동시에 확보할 뿐만 아니라 검수 기준으로 활용

5.6 검수 후 피드백 프로세스

- 검수 후의 피드백 프로세스는 다음과 같음
 - 검수 후 불합격 판정 → 검수 의견 제시 (추출요약과 생성요약의 문제점을 검수자가 기록) → 문서가공자에게 재전달 → 2차 가공 → 2차 검수 → 불합격의 경우 재가공 요청 (검수 의견 기록) → 문서 재가공 (3차 가공) → 3차 검수
- 3차 검수 결과가 불합격인 경우 1) 문서가 매우 어려워 가공자가 가공할 수 없음, 2) 가공자의 역량이 그 문서를 요약할 능력이 되지 않음, 3) 문서의 형태가 가공이 불가능함 등의 사유로 가공 불능 데이터로 판정하고, 3차 검수 불합격 데이터를 별도 저장하여 향후 다른 작업자를 통해 재가공할 예정
- 가공시 정확도를 높이기 위해 검수 합격된 문서에만 보상을 명문화하였음
- 클라우드소싱의 특성상 작업자에 대한 교육이 어려운 관계로, 검수시 검수의견을 최대한 명확하고 구체적으로 전달할 계획임

6. 활용

6.1 활용 모델

6.1.1 모델 학습

□ 추출요약 모델 (1) - NeuSum

- Zhou 외 (2018)가 제안한 순환신경망(RNN) 기반의 추출 요약 모델인 NeuSum은 문장의 중요도 산정(sentence scoring)과 문장 선택(sentence selection)을 동시에 하는 모델임
- NeuSum은 크게 단어 수준의 표현 학습, 문장 수준의 표현 학습, 추출 요약의 3가지 단계로 나눌 수 있음
- 단어 수준의 표현 학습에서는 양방향 순환신경망의 한 종류인 Bi-RNN(Bidirectional RNN)을 사용하며 Bi-RNN의 마지막 히든 유닛을 이용해 문장 임베딩을 구함
- 문장 수준의 표현 학습에서는 앞서 구한 문장 임베딩을 입력으로 하는 Bi-RNN을 사용함
- 마지막으로 앞에서 구한 문장 임베딩을 입력으로 받는 RNN을 통해 추출 요약을 수행함
- 추출 요약 모델을 학습할 때 사용하는 학습 데이터의 정답 레이블은 일반적인 one-hot 레이블을 사용하는 것이 아닌, 각 문장을 선택했을 때의 ROUGE score의 변화량을 label로 사용함
- 해당 모델을 학습하기 위해서는 최소 NVIDIA GTX 1080TI 이상의 사양을 갖는 그래픽카드가 필요함

□ 추출요약 모델 (2) - BERTSumExt

- BERTSumExt는 사전학습된 BERT모델에 추가적인 Transformer Encoder 모델을 사용해 추출 요약을 수행함
- 사전학습된 BERT가 여러 개의 문장을 입력 데이터로 받았을 때 한 번의 분류밖에 수행할 수 없는 반면 BERTSumExt는 문장당 한 번의 분류를 수행할 수 있도록 입력 데이터의 구조를 변경함
- 입력 데이터가 사전학습된 BERT를 거친 뒤 출력 결과 중 문장마다 존재하는 special token([CLS])에 해당하는 부분만 추출해 Transformer의 입력 데이터로 사용함
- Transformer를 거쳐 나온 가장 마지막 층(layer) 이후 각 문장이 추출 요약에 포함될 문장인지를 판단하는 이진 분류를 수행함
- 해당 모델을 학습하기 위해서는 최소 NVIDIA GTX 1080TI 이상의 사양을 갖는 그래픽카드가 필요함

□ 생성요약 모델 (1) - PointerGenerator

- PointerGenerator는 기존 RNN기반 Sequence-to-sequence + Attention 모델을 기반으로 하는 생성 요약 모델임
- PointerGenerator는 Pointer-generator Network와 Coverage Mechanism을 사용함으로써 기존의 Sequence-to-sequence 기반 생성 요약 모델이 갖고 있던 단점인 정확하지 않은 정보를 만들거나 어휘 사전에 없는 단어를 처리하는 등의 문제점을 보완함
- Pointer-generator Network는 별도의 출력 단어 생성 확률값을 도입하여 생성하는 요약 단어를 어휘 사전에서 추출할지 입력 문장에서 추출할지를 결정함으로써 생성요약의 단점을 추출요약으로 보완함
- Coverage Mechanism은 출력 단어가 반복적으로 나타나는 현상을 방지하는 기법으로 특정 시점까지 등장한 출력 결과물의 attention 분포를 합한 coverage vector를 적용하여 특정 분포의 단어가 반복적으로 생성되지 않도록 함
- 또한, 기존 손실함수에 반복적으로 생성되는 단어에 대한 벌점(penalty)을 부여하는 손실함수를 추가함
- PointerGenerator는 입력 문장에서도 요약문을 추출할 수 있어 기존의 모델보다 상대적으로 적은 데이터가 있어도 성능을 유지함
- 해당 모델을 학습하기 위해서는 최소 NVIDIA GTX 1080TI 이상의 사양을 갖는 그래픽카드가 필요함

□ 생성요약 모델 (2) - BERTSumAbs

- BERTSumAbs는 Encoder와 Decoder로 이루어진 Sequence-to-sequence architecture를 따르며 encoder는 사전학습된 BERT모델을, decoder는 임의로 초기화된 Transformer모델을 사용함
- 위와 같은 방식을 사용해 문서 요약을 학습시킬 경우 학습이 불안정할 수 있어 이를 완화하기 위해 encoder와 decoder 각각 개별적인 Optimizer를 사용하는 방식을 차용함
- 생성 요약을 수행하기 전 사전학습된 BERT모델 을 추출 요약으로 미세 조정(finetuning)을 하는 것이 성능 향상을 도움이 되기 때문에 encoder의 BERT모델에 미세 조정을 진행한 후 생성 요약에 대한 학습을 수행함
- 해당 모델을 학습하기 위해서는 최소 NVIDIA GTX 1080TI 이상의 사양을 갖는 그래픽카드가 필요함

□ 권장 학습 분배량

- 구축된 데이터를 훈련 집합, 검증 집합, 테스트 집합으로 분배함
- 훈련 집합은 모델을 학습하는 데 사용됨
- 검증 집합은 모델의 하이퍼 파라미터 조합을 탐색하는 데 사용되며 검증 집합을 통해 모델의 성능을 측정함으로써 가장 좋은 성능을 보인 최적의 파라미터 조합을 찾을 수 있음
- 테스트 집합은 최적의 모델을 찾는 데 사용되는 데이터 집합으로 앞서 검증 집합을 이용해 각 모델 별 최적의 파라미터

- 훈련, 검증, 테스트 집합은 7 : 1.5 : 1.5의 비율로 분배하는 것을 권장함

- 모델과 학습 파일이 있는 소스코드를 다운 받음

- 모델과 학습 파일이 있는 소스코드를 다운 받음
- 모델 소스코드는 데이터와 함께 AI Hub에 배포하거나, GitHub 공개 저장소를 구축해 pip로 배포함으로써 지속적으로 업데이트되도록 함
- 각 모델들은 파이썬 라이브러리인 pytorch lightning을 이용해 구현되었으며 이를 통해 학습 및 검증, 테스트를 모두 수행함

- 앞서 설명된 대표 모델 중 학습에 사용할 모델을 선택함

- 모델 별로 학습을 수행할 수 있는 모델명_main.py 파일이 존재함(예: pointer_generator_main.py)

- 두 가지 방식을 통해 학습에 필요한 하이퍼파라미터를 설정할 수 있음


- 첫 번째로 python의 argparse 모듈을 이용하는 방법이 있으며 이 경우 main.py 파일을 실행할 때 각 하이퍼파라미터를 함께 입력함
- 두 번째로 하이퍼파라미터 폴더에 있는 에 있는 hparam.json파일을 수정함으로써 하이퍼파라미터를 설정할 수 있음

- 터미널을 실행해 소스코드가 있는 폴더에서 `python train.py`를 입력함으로써 학습을 수행함

- argparse 모듈을 이용해 하이퍼파라미터를 설정한 경우 해당 하이퍼파라미터를 main.py뒤에 입력함(예: pointer_generator_main.py --batch_size=64 --learning_rate=2e-4 ...)
- json 파일을 이용해 하이퍼파라미터를 설정한 경우 main.py뒤에 json을 입력함(예: pointer_generator_main.py --json)
- 검증과 테스트는 하이퍼파라미터 validation, test를 입력함으로써 수행할 수 있음

☐ 원문 요약 API

- (서비스 개요) 원문을 입력하면 원문의 요약문과 시각화 결과를 제공하는 서비스
- (필요성) 온라인 환경 상에서 다양한 형태로 이루어진 정보 축약이 요구됨
 - 방대한 정보들 속에서 필요한 정보만을 골라냄으로써 요약 및 발췌해주는 콘텐츠를 소비하는 것을 '클리핑 신드롬'이라고 부르고 있음
 - SNS 세대에서 보다 빠른 정보 습득과 전달을 위해 정보는 간단하고, 축약될수록 좋음
- (프레임워크) 원문 요약 API의 프레임워크는 [그림 1]에서 보여지는 바와 같음
 - 원문 유형에 따른 요약 모델을 활용함



- (GUI 구성) 원문 요약 API의 GUI 구성은 [그림 2]와 같음

- 사용자의 입력에는 원문(텍스트 또는 파일), 원문 유형, 요약 방식(추출, 생성, 키워드), 요약 분량(한줄, 세줄)이

원문은 유

- 있음

[illegible]

[그림 15] 원문 요약 API GUI 구성


- 활용 시나리오

- 인터넷, 스마트폰, 신문과 같은 다수의 매체로부터 정보를 습득하는 과정에 있어 속도 증진

☐ 고품질 뉴스 기사 판단 및 요약 서비스

- (서비스 개요) 세 가지 요소 (1) 콘텐츠 품질 지표, (2) 구조의 명확성, (3) 정보량을 기반으로 기사의 품질을 평가하는 서비스
- (필요성1) 포털 환경에서의 수익구조로 인한 저품질의 뉴스 양산 증가
 - 언론사는 포털에서 뉴스 이용자의 클릭 유도를 위해 비용 대비 수익 창출 효과가 큰 자극적이고 품질이 낮은 기사 생산에 초점을 둬
- (필요성2) 좋은 품질의 뉴스 소비 환경 조성을 위한 품질 평가가 요구됨
 - 로이터 저널리즘 연구소에 따르면 2017년 세계 36개국을 대상으로 실시한 조사에서 한국의 뉴스 신뢰도는 23%에 불과하며, 최하위에 속함¹⁾
 - 신뢰도 회복을 위해 뉴스 품질 평가를 통한 개선이 필요한 상황임
- (프레임워크) 고품질 뉴스 기사 판단 및 요약 서비스 프레임워크는 [그림 3]에서 보여지는 바와 같음

1) 영국 옥스퍼드대학교 부설 로이터저널리즘연구소, 디지털뉴스리포트 2019.



[그림 16] 고품질 뉴스 기사 판단 및 요약 서비스 프레임워크

- (품질 평가 요소) 뉴스 품질은 세 가지 요소에 의해 평가됨
 - PEJ(project for excellence in journalism) 지수 기반(레이블링 관련 사항 논의중) 품질 예측 : 레이블링된 기사 데이터를 학습한 모델로 입력 기사에 대한 품질 예측
 - 결과물로는 입력 기사의 품질(레이블 방식에 따라 달라질 수 있음)과 품질 판단 근거가 있음
 - 원문 요약 : 원문 뉴스를 간단히 요약
 - 결과물로는 요약문에 대한 확률(%)과 요약문이 있음
 - 정보량 측정 : 원문 내 정보량 측정 및 타 기사와의 정보량 비교
 - 결과물로는 상대 정보량(%)과 유사 기사 중 게시 시점이 선행하는 정도(%)가 있음
 - 단, 유사 기사들 중 게시 시간의 선행하는 정도는 프로토타입으로만 제공하며, 지속적인 데이터의 입력이 불가능하므로 실서비스에서 활용에 어려움이 존재
- (GUI 구성) 고품질 뉴스 기사 판단 및 요약 서비스의 GUI 구성은 [그림 4]와 같음
 - 사용자의 입력은 기사 원문(텍스트, 파일, 그리고 다수의 파일을 포함하는 폴더의 경로 중 하나)임
 - 서비스 개발을 위해 사용되는 데이터는 구축되어 있는 원문과 요약문 쌍 중 기사, 품질에 대한 평가(label), 메타 정보(기사 게시일, 작성 기자 수)

Figure 17 shows the GUI of the High-Quality News Article Evaluation and Summary Service, divided into two main sections: Input and Result.

- 입력 (Input):**
 - 뉴스 제목 (News title): Text input field
 - 뉴스 원문 (News original text): Text area with a note: "10자 이상의 한글을 입력해주시기 바랍니다." (Please enter at least 10 Korean characters.)
 - 파일 업로드(.txt, .docx, .hwp) (File upload): File selection button
 - 폴더 업로드 (Folder upload): Folder selection button
 - 찾아보기 (Find): Search button
 - 초기화 (Reset): Reset button
 - 측정 (Measure): Measure button
- 결과 (Result):**
 - 품질: 양호 (Quality: Good)
 - 판단 근거: (Judgment basis: Table with 3 columns: 항목, 값, 평가)
 - 요약 모델 확률(%): 75.12
 - 요약문: (Summary text)
 - 정보량(%): 80.54
 - 유사 기사 중 게시 선행 정도(%): 68.89
 - 정보량 분포 (Information distribution graph)
 - 유사 기사 게시 시간 분포 (Similar article posting time distribution graph)

[그림 17] 고품질 뉴스 기사 판단 및 요약 서비스 GUI 구성

- 활용 시나리오
 - 다수의 뉴스 기사의 경우 보도자료를 크게 수정하지 않고 게재되어 보다 낮은 품질의 기사가 생산되므로 언론사 자체적으로 생산한 기사의 질적 수준을 평가하도록 함

붙임1

인공지능 데이터 명세서_문서요약 텍스트 AI데이터

데이터 이름	문서요약 텍스트 AI데이터	
데이터 포맷	데이터 포맷 참조	
활용 분야	뉴스기사 요약, 법률분서 요약, 사업보고서 요약 등 핵심내용을 신속하고 정확하게 파악할 수 있는 AI 요약기술 개발에 활용	
데이터 요약	다양한 한국어 원문데이터로부터 정제된 추출 및 생성 요약문을 도출하고 검증한 한국어 문서요약 AI 데이터셋	
데이터 출처	전국종합일간, 지역종합일간, 경제일간, 스포츠일간, 전문일간, 전문주간 등 60개 언론매체로부터 신문 (30만 건), 기고문 (6만 건), 잡지 (1만 건), 법률 (3만 건)의 원시데이터 확보	
데이터 이력	배포버전	TextSummaryAIDataset_ver1.
	개정이력	신규
	작성자/ 배포자	작성자/배포자 : 최재웅
데이터 구성	데이터 구성 참조	
어노테이션 포맷	어노테이션 포맷 참조	
데이터 통계	데이터 구축 규모	원문 총 40만 건, 요약문 총 80만 건 (추출요약 40만 건 / 생성요약 40만 건)
	데이터 분포	데이터 분포 참조
	기타 활용 통계	해당사항 없음
기타 정보	대표성 (Coverage)	기타정보 참조
	독립성	
	유의사항	
	관련 연구	해당사항 없음

□ 데이터 포맷

[원문데이터 포맷 예시]

제목	
국민은행, '청소년의 멘토 KB 공부방' 700호 전달	
매체유형	경제지
매체명	강원일보
카테고리	경제
기사크기	소 (979자)
발행일	2018.04.02
원문	
KB국민은행은 서울 성동구 성수동에서 구세군자선냄비본부와 함께 '청소년의 멘토 KB 공부방' 700호 전달식을 가졌다고 18일 밝혔다. 청소년의 멘토 KB 공부방 조성은 소외계층 청소년들이 자신만의 공간에서 꿈과 희망을 키울 수 있도록 맞춤형 공간을 조성해 주는 사업이다. 지난 2012년부터 올해 1월까지 총 700가구에 공부방을 지원했으며, 올해 100가구를 추가로 지원할 예정이다. 이번 700호에 선정된 가정은 낡은 연립주택의 10평 남짓한 작은 공간에 아버지와 자매 등 총 3명의 가족이 함께 생활하고 있다. 오래된 책상과 의자, 곰팡이로 가득한 벽지에, 세면대조차 없는 화장실에는 변기마저 파손돼 정상적인 이용이 어려운 열악한 환경이었다. 이에 KB국민은행은 공부방 조성이 아닌 실내 인테리어 전반에 대한 대규모 공사를 진행했다. 도배, 장판, 창호, 싱크대 교체, 화장실 개·보수 등의 생활공간 개선 및 책상, 의자, 옷장 등 친환경 원목가구와 학습에 필요한 컴퓨터, 스탠드 등의 물품이 제공돼 쾌적한 공간으로 재탄생 했다.	
전처리 후	
KB국민은행은 서울 성동구 성수동에서 구세군자선냄비본부와 함께 '청소년의 멘토 KB 공부방' 700호 전달식을 가졌다고 18일 밝혔다. 청소년의 멘토 KB 공부방 조성은 소외계층 청소년들이 자신만의 공간에서 꿈과 희망을 키울 수 있도록 맞춤형 공간을 조성해 주는 사업이다. 지난 2012년부터 올해 1월까지 총 700가구에 공부방을 지원했으며, 올해 100가구를 추가로 지원할 예정이다. 이번 700호에 선정된 가정은 낡은 연립주택의 10평 남짓한 작은 공간에 아버지와 자매 등 총 3명의 가족이 함께 생활하고 있다. 오래된 책상과 의자, 곰팡이로 가득한 벽지에, 세면대조차 없는 화장실에는 변기마저 파손돼 정상적인 이용이 어려운 열악한 환경이었다. 이에 KB국민은행은 공부방 조성이 아닌 실내 인테리어 전반에 대한 대규모 공사를 진행했다. 도배, 장판, 창호, 싱크대 교체, 화장실 개·보수 등의 생활공간 개선 및 책상, 의자, 옷장 등 친환경 원목가구와 학습에 필요한 컴퓨터, 스탠드 등의 물품이 제공돼 쾌적한 공간으로 재탄생 했다.	

[JASON 형식]

```
▼ object {3}
  name : sample1
  annotation_date_time : 2020-07-02 00:01:21
  ▼ documents [1]
    ▼ 0 {12}
      id : 12345
      category : 경제
      media_type : online
      media_sub_type : 지역지
      media_name : 강원일보
      size : small
      char_count : 979
      publish_date_time : 2018-04-02 00:01:21
      ► text [2]
      ► quality_scores {4}
      ▼ extractive [3]
        0 : 2
        1 : 4
        2 : 10
      abstractive : The abstractive summary goes here
```

□ 데이터 구성

Key	Description	Type	Child Type
name	파일명	String	
delivery_date	생성시간 yyyy-MM-dd hh:mm:ss	String	
documents	문서 배열	JSONArray	JsonObject
[	문서	JsonObject	
id	문서 아이디	String	
category	카테고리	String	
media_type	미디어 유형 (ex: online)	String	
media_sub_type	비디어 유형 (ex: 중앙지)	String	
media_name	미디어 명 (ex: 국민일보)	String	
size	길이 (ex: small)	String	
char_count	본문길이	String	
publish_date	게시시간 yyyy-MM-dd hh:mm:ss	String	
title	제목	String	
text	본문(문단/문장)	JSONArray	JSONArray
[	문단	JSONArray	JsonObject
[	문장		
index	순번	String	
sentence	문장	String	
highlight_indices	불용어 위치 정보	String	
]			
]			
]			

□ 어노테이션 포맷

No	항목		길이	타입	필수여부	비고
		한글명	영문명			
1		데이터셋 정보		JsonObject	Y	
	1-1	데이터셋 명	name	String	Y	
	1-2	데이터셋 전달일자	delivery_date	String	Y	yyyy-mm-dd hh:mm:ss
2		문서 정보		JsonObject	Y	
	2-1	문서 번호	id	String	Y	
	2-2	카테고리	category	String	Y	예) 문서번호
	2-3	매체 유형	media_type	String	Y	예) 온라인
	2-4	매체 구분	media_sub_type	String	Y	예) 중앙지
	2-5	미디어 명	media_name	String	Y	예) 국민일보
	2-6	본문길이	size	String	Y	
	2-7	본문글자수	char_count	String	Y	
	2-8	발행일시	publish_date	String	Y	yyyy-mm-dd hh:mm:ss
	2-9	제목	title	String	Y	
3		본문(문단/문장) 정보	text	Array	Y	
	3-1	문단	[	Array	Y	
	3-2	문장	{	JsonObject	Y	
	3-3	순번	index	Integer	Y	
	3-4	문장	sentence	String	Y	
	3-5	불용어 위치 정보	highlight_indices	String	Y	
			}			
			]			
4		원문 평가 정보		JsonObject	Y	
	4-1	가독성	readable	Integer	Y	
	4-2	정확성	accurate	Integer	Y	
	4-3	정보성	informative	Integer	Y	
	4-4	신뢰성	trustworthy	Integer	Y	
5		추출요약문 정보	extractive	Array	Y	
6		생성요약문 정보	abstractive	Array	Y	

실제 예시

```
{
  "name": "문서요약 프로젝트",
  "delivery_date": "2020-09-08 11:36:41",
  "documents": [
    {
      "id": "343753195",
      "category": "정치",
      "media_type": "online",
      "media_sub_type": "지역지",
      "media_name": "광주매일신문",
      "size": "small",
      "char_count": "814",
      "publish_date": "2019-05-02 18:32:00",
      "title": "군 공항 이전사업 홍보 영상물 만든다",
      "text": [
        [
          {
            "index": 0,
            "sentence": "市, 국방부·전남도 협의 통해 이전 후보지서 필요성 설명",
            "highlight_indices": ""
          },
        ],
        ...
      ],
      "document_quality_scores": {
        "readable": 4,
        "accurate": 4,
        "informative": 3,
        "trustworthy": 4
      },
      "extractive": [
        2,
        3,
        4
      ],
      "abstractive": [
        " 광주시에 따르면 국방부·전남도와 협의해 후보지를 직접 찾아가 주민들에게 사업의 필요성을 설명할 사업 소개
        와 함께 후보지로 선정되면 지원되는 다양한 사업이 상세하게 담긴 군 공항 이전사업 관련 홍보 영상물을 제작 중이다."
      ]
    },
    .....
  ]
}
```

□ 데이터 통계

○ 데이터 구축 규모

데이터 종류	데이터 형태	원문 규모		어노테이션 규모	결과물 규모	
					추출요약	생성요약
신문기사	뉴스 텍스트	30만 건	소 : 10만건 중 : 10만건 대 : 10만건	60만 건	30만건 (3문장 추출)	30만건 (1문장 생성)
기고문	오피니언 텍스트	6만 건		12만 건	6만건 (3문장 추출)	6만건 (1문장 생성)
잡지	웹진 기사 텍스트	1만 건		2만 건	1만건 (3문장 추출)	1만건 (1문장 생성)
법률	법원 판결문 뉴스텍스트 및 법원 주요판결문 텍스트	3만 건		6만 건	3만건 (3문장 추출)	3만건 (1문장 생성)
총계		40만 건		80만 건	40만건 (3문장 추출)	40만건 (1문장 생성)

※ 원문 데이터 규모 : 소 (~700자), 중 (700~1,000자), 대 (1,000~1,500자)로 구분

○ 데이터 분포

- 매체별 분포 : 전국종합일간, 지역종합일간, 경제일간, 전문일간, 잡지, 법원판결문 원문 건수
- 주제별 분포 : 종합, 정치, 경제, 사회, 문화, 스포츠 IT/과학, 주장(기고), 시사, 문화예술, 기타, 판결문, 인문학, 사회과학, 예술/체육 원문 건수

[매체별 분포]

구분	원문 건수	비율
전국종합일간	18만건	45%
지역종합일간	5만건	12.5%
경제일간	5만건	12.5%
전문일간	5만건	12.5%
잡지	1만건	2.5%
법원판결문	6만건	15%
합계	40만건	잘못된 계산식%

[주제별 분포]

구분		원문 건수	비율
신문	종합	9만건	22.5%
	정치	3만7,500건	9.3%
	경제	3만7,500건	9.3%
	사회	3만7,500건	9.3%
	문화	3만7,500건	9.3%
	스포츠	3만건	7.5%
	IT/과학	3만건	7.5%
기고문	주장 (기고)	3만건	7.5%
잡지	시사	5,000건	1.25%
	문화예술	3,000건	0.75%
	기타	2,000건	0.5%
법률	판결문	6만건	15%
합계		40만 건	100%

□ 기타 정보

○ 데이터 대표성

- 언론진흥재단을 통해 계약한 60개 언론매체 및 직계약을 체결한 4개 언론매체의 2년치 데이터 약 80만 건 중, 데이터 형태, 주제, 데이터 크기 등 조건에 부합하는 총 30만 건의 데이터를 원문데이터로 선정함

○ 데이터 독립성

- 원시데이터는 이용기간의 제한이 없는 영구적인 저작권이 확보되어 있으며, 원시데이터를 제공한 각 언론매체는 AI 알고리즘 개발 목적의 영구적 활용에 동의하였으므로 향후 데이터 이용에 대한 독립성이 보장됨
- 또한 원문데이터 선정과정에서 개인정보 등 향후 문제가 될 수 있는 내용은 필터링을 거쳐 선정하여 데이터의 독립성을 확보함

○ 데이터 활용시 유의사항

- AI허브에 공개되는 원문데이터와 요약데이터는 오로지 AI 알고리즘 개발 목적으로 공개되었으며, 그 외 일체의 상업적 목적을 위한 활용을 금함