

스프린트 미션 16: AI 숫자 예측

AI 숫자 예측

연구기간: 2025.12.15 ~ 2025.12.18

연구자: 김명환 (AI 4 기 3 팀)

완료일: 2025.12.12


1. 프로젝트 개요

본 프로젝트는 ONNX (Open Neural Network Exchange) 형식의 MNIST 모델을 활용하여 사용자가 웹 캔버스에 그린 숫자를 실시간으로 예측하는 Streamlit 기반 웹 서비스를 개발하고 Docker 컨테이너로 배포하는 것을 목표로 합니다.

1.1. 기술 스택

- 프레임워크: Streamlit
- 모델: ONNX MNIST (mnist-8.onnx)
- 추론 엔진: ONNX Runtime
- 이미지 처리: OpenCV, NumPy, Pillow
- 컨테이너화: Docker
- 배포: Docker Hub (c0z0c/digit-vision:v1.1)

2. 시스템 아키텍처



2.1. 데이터 흐름

- 입력: 사용자가 200x200 캔버스에 숫자를 그림 (검은색 선/흰색 배경)
- 전처리: 28x28 그레이스케일로 변환 및 정규화 (normalization, 노멀라이제이션)
- 추론: ONNX Runtime을 통한 모델 예측
- 출력: 0-9 숫자 예측 결과 및 확률 분포 (probability distribution, 프로바빌리티 디스트리뷰션)
- 저장: 예측 기록을 세션 상태 및 파일 시스템에 저장

3. 핵심 기능 개선 사항

3.1. 이미지 전처리 최적화

본 프로젝트의 가장 중요한 개선 사항은 바운딩 박스 (bounding box, 바운딩 박스) 기반 전처리 기법을 도입하여 모델 예측 성능을 향상시킨 것입니다.

3.1.1. 전처리 알고리즘

기존 방식 (use_bbox_resize=False):

- 200x200 캔버스 → 28x28 직접 리사이즈

- 배경 영역이 과도하게 포함되어 숫자가 상대적으로 축소됨
- 낮은 신뢰도 (confidence, 컨피던스)

개선 방식 (use_bbox_resize=True):

- 단계 1: 그레이스케일 변환 (grayscale conversion)
- 단계 2: 색상 반전 (inversion) - 흰색 숫자/검은색 배경
- 단계 3: 바운딩 박스 추출 (임계값 > 10)
- 단계 4: 비율 유지 리사이즈 (19x19 이내, 24x24의 80%)
- 단계 5: 28x28 캔버스 중앙 배치
- 단계 6: 정규화 (0~255 → 0.0~1.0)
- 단계 7: 형태 변경 (28, 28) → (1, 1, 28, 28)

3.1.2. 핵심 파라미터

- target_size: (28, 28) - MNIST 모델 입력 크기
- target_content_size: 19 픽셀 - 바운딩 박스 최대 크기 (24 x 0.8)
- bbox_threshold: 10 - 배경 노이즈 제거 임계값

3.2. 전처리 성능 비교 분석

history 디렉토리의 metadata.json과 이미지 파일을 분석한 결과:

3.2.1. Record 1: 숫자 0 예측

항목	canvas_1.png (전처리 전)	canvas_2.png (전처리 후)
예측 레이블	2	0
신뢰도	49.26%	99.9998%
결과	오예측	정답

전처리 전에는 숫자 0을 2로 잘못 예측했으나, 바운딩 박스 기반 전처리 적용 후 99.9998%의 높은 신뢰도로 정확히 예측함.

3.2.2. Record 2: 숫자 1 예측

항목	canvas_3.png (전처리 전)	canvas_4.png (전처리 후)
예측 레이블	3	1
신뢰도	19.28%	99.99%
결과	오예측	정답

전처리 전에는 숫자 1을 3으로 잘못 예측했으며 신뢰도도 19.28%로 매우 낮았음. 전처리 후 99.99% 신뢰도로 정확히 예측함.

3.2.3. Record 3: 숫자 2 예측

항목	canvas_5.png (전처리 전)	canvas_6.png (전처리 후)
예측 레이블	5	2
신뢰도	17.87%	99.9997%
결과	오예측	정답

전처리 전에는 숫자 2를 5로 잘못 예측했으며 신뢰도도 17.87%로 매우 낮았음. 전처리 후 99.9997% 신뢰도로 정확히 예측함.

3.3. 성능 개선 요약

$$\text{신뢰도 향상률} = \frac{\text{전처리 후 평균 신뢰도} - \text{전처리 전 평균 신뢰도}}{\text{전처리 전 평균 신뢰도}} \times 100$$

$$= \frac{99.996\% - 28.80\%}{28.80\%} \times 100 \approx 247\%$$

- 예측 정확도: 0% → 100% (3건 모두 오예측 → 정답)
- 평균 신뢰도: 28.80% → 99.996% (약 3.5배 향상)
- 전처리 핵심: 24x24의 80% 크기 (19픽셀)로 비율 유지 리사이즈

4. 소스코드 구조

4.1. 모듈별 역할

4.1.1. ImagePreprocessor (이미지 전처리)

- 파일: src/model/ImagePreprocessor.py
- 핵심 메서드:
 - ✧ preprocess(): 전체 전처리 파이프라인
 - ✧ _get_bounding_box(): 바운딩 박스 추출
 - ✧ _resize_with_aspect_ratio(): 비율 유지 리사이즈
 - ✧ _place_on_canvas(): 중앙 배치

4.1.2. ONNXPredictor (모델 추론)

- 파일: src/model/ONNXPredictor.py
- 핵심 기능:
 - ✧ ONNX Runtime 세션 관리
 - ✧ Softmax 활성화 함수 적용
 - ✧ 확률 분포 (probability distribution) 계산

4.1.3. MNISTPipeline (통합 파이프라인)

- 파일: src/model/MNISTPipeline.py
- 핵심 기능:
 - ✧ 모델 다운로드 및 초기화
 - ✧ 전처리와 추론의 통합 인터페이스
 - ✧ use_bbox_resize 파라미터로 전처리 방식 선택

4.2. 주요 데이터 클래스

- ModelConfig: 모델 설정 (입력 형태, URL 등)
- PredictionResult: 예측 결과 (레이블, 신뢰도, 확률 분포)
- HistoryRecord: 예측 기록 (타임스탬프, 이미지 해시)

5. Docker 컨테이너화

5.1. Docker 이미지 정보

- 이미지명: c0z0c/digit-vision:v1.1
- 베이스 이미지: python:3.10-slim
- 포트: 8501 (Streamlit 기본 포트)

5.2. 실행 방법

```
docker pull c0z0c/digit-vision:v1.1
docker run -p 8501:8501 c0z0c/digit-vision:v1.1
```

5.3. 배포 전략

- 모델 캐싱: @st.cache_resource를 활용하여 ONNX 모델을 메모리에 유지
- 세션 상태: st.session_state로 사용자별 예측 기록 관리
- 파일 저장: history 디렉토리에 이미지와 메타데이터 영구 저장

6. 실행 결과

6.1. UI 구성

애플리케이션은 4개의 주요 영역으로 구성됩니다:

- 캔버스 영역: 200x200 크기의 그리기 영역
- 전처리 이미지: 28x28 변환 결과 표시
- 추론 결과: 막대 차트 (bar chart, 바 차트)로 확률 분포 시각화
- 이미지 저장소: 예측 기록 테이블 형식 표시

6.2. UI/UX 최적화

브라우저 페이지의 공간 활용을 최적화하기 위해 src/utils/utils_st.py 모듈을 개발하여 UI 개선을 수행했습니다:

6.2.1. 여백 최소화

- hidden_page_top_margin(): CSS를 활용하여 페이지 상단 여백을 최소화
 - ✧ Streamlit 헤더와 툴바 숨김 처리
 - ✧ 메인 컨테이너의 padding-top을 0으로 설정
 - ✧ 모든 텍스트 요소의 margin과 padding 제거

6.2.2. 컴팩트 구분선

- minimal_divider(): 기본 st.markdown("---") 대신 여백이 최소화된 커스텀 구분선 사용
 - ✧ 높이 1px의 얇은 가로선 (배경색: #ddd)
 - ✧ margin과 padding을 0으로 설정하여 상하 여백 제거
 - HTML div 태그를 직접 렌더링하여 구현

이러한 최적화를 통해 페이지에 표시되는 콘텐츠를 더욱 효율적으로 배치하고 사용자 경험을 향상시켰습니다.

6.3. 예측 성능 검증

metadata.json의 6건의 예측 기록 분석 결과:

- Record 1: 예측=2, 신뢰도=49.26% (전처리 전 오예측)
- Record 2: 예측=0, 신뢰도=99.9998% (전처리 후 정답)
- Record 3: 예측=3, 신뢰도=19.28% (전처리 전 오예측)

- Record 4: 예측=1, 신뢰도=99.99% (전처리 후 정답)
- Record 5: 예측=5, 신뢰도=17.87% (전처리 전 오예측)
- Record 6: 예측=2, 신뢰도=99.9997% (전처리 후 정답)

7. 결론

7.1. 주요 성과

- 전처리 알고리즘 개선: 바운딩 박스 기반 전처리 도입으로 예측 정확도 100% 달성
- 성능 향상: 평균 신뢰도 28.80% → 99.996% (약 247% 향상)
- 최적화 파라미터: 24x24의 80% 크기 (19픽셀)로 비율 유지 리사이즈가 핵심
- 컨테이너 배포: Docker Hub를 통한 재현 가능한 배포 환경 구축


7.2. 기술적 의의

- 모듈화 설계: 전처리, 추론, 시각화, 히스토리 관리를 독립적인 클래스로 분리
- 유연한 전처리: use_bbox_resize 파라미터로 전처리 방식 선택 가능
- 확장 가능성: ONNX 포맷을 통한 다양한 모델 호환 가능

7.3. 향후 개선 방향

- 전처리 파라미터 튜닝: target_content_size 최적값 탐색
- 모델 업그레이드: 더 큰 MNIST 변형 모델 적용
- UI/UX 개선: 실시간 전처리 프리뷰, 예측 히스토리 검색 기능
- 성능 모니터링: 추론 시간, 메모리 사용량 측정 및 최적화

시연 영상



<https://youtu.be/TS62AbviDRg>

<http://c0z0c-dev-digit-vision.streamlit.app>