포르투갈 은행 마케팅 데이터 분석 연구보고서

머신러닝 기반 예측 및 마케팅 전략 도출

포르투칼 은행 마케팅 데이터 분석 연구
연구 기간: 2025.07.25 - 2025.07.30
연구자: 김명환 (AI 4기 5팀)
완료일: 2025년 7월 30일

---

1. 서론

- 연구 배경
  - 2008~2010년 글로벌 금융위기 시기, 포르투갈 은행의 정기예금 마케팅 캠페인 데이터 분석
- 비즈니스 목표
  - 정기예금 가입 예측 및 마케팅 효율성 극대화 전략 도출
- 분석 목표
  - 결정 트리 및 앙상블 기법 기반 예측모델 개발, 실무 적용 인사이트 도출
- 배경
  - 2008년(5월~12월): 글로벌 금융 위기가 확산되며 경기 둔화의 조짐이 나타나기 시작했고, 정부는 금융 시스템 안정화에 주력했습니다.
  - 2009년: 금융 위기의 직격탄을 맞아 GDP가 크게 위축되고 실업률이 급등하는 등 심각한 경기 침체를 겪었습니다.
  - 2010년(1월~11월): 경기 침체에서 벗어나지 못하고 국가 재정 적자 및 부채 문제가 부각되어 유로존 재정 위기의 핵심 국가로 부상하기 시작했습니다.

---

2. 데이터 이해

2.1 변수 설명

변 수명	설명	타입	비고
education	교육 수준	category	8개 등급(대학교, 고등학교, 전문, 문맹 등), 금융이해도/소득 추정
default	신용 불량 여부	category	yes(신용불량), no(정상), unknown(미상), 신용위험도 지표
housing	주택 대출 여부	category	yes(대출 있음), no(없음), unknown(미상), 신용/자산상태 반영
loan	개인 대출 여부	category	yes(대출 있음), no(없음), unknown(미상), 신용/부채상태 반영
contact	연락 방식	category	cellular(휴대폰), telephone(유선전화), 마케팅 채널 효과 분석
month	마지막 연락 월	category	jan~dec(월별), 계절성/시기별 효과 반영
day_of_week	마지막 연락 요일	category	mon~fri(월~금), 요일별 캠페인 효과 분석
duration	통화 지속 시간(초)	int	**모델에서 제외** (예측 불가 정보, 결과분석용)
campaign	현재 캠페인 연락 횟수	int	1~56회, 3~4회 최적, 20회 이상은 이상치 가능(고객 피로도)
pdays	이전 캠페인 후 경과 일수	int	999: 이전 캠페인 없음(신규 고객), 0~998: 마지막 접촉 후 경과일수(재접촉)
previous	이전 캠페인 연락 횟수	int	과거 캠페인 연락 횟수(0~7회, 대부분 0), 재참여/리텐션 지표
poutcome	이전 캠페인 결과	category	success(성공), failure(실패), nonexistent(연락없음), 과거 마케팅 효과
emp.var.rate	고용 변동률	float	분기별, 경제상황 반영(%), 거시경제 변수
cons.price.idx	소비자 물가지수	float	월별, 구매력/물가 지표, 거시경제 변수
cons.conf.idx	소비자 신뢰지수	float	월별, 경제 심리/소비심리 지표, 거시경제 변수
euribor3m	3개월 유리보 금리	float	일별, 자금조달 비용/금리, 거시경제 변수
nr.employed	고용자 수	float	분기별, 경제 규모(천명 단위), 거시경제 변수
y	정기 예금 가입 여부	category	타겟 변수(yes/no), 이진 분류

2.2데이터셋 기본 정보

- 출처: UC Irvine Machine Learning Repository - Bank Marketing Dataset
- 기간: 2008년 5월 ~ 2010년 11월 (시간순 정렬)
- 규모: 41,188개 행, 21개 컬럼 (20개 입력 변수 + 1개 타겟 변수)

- 목적: 포르투갈 은행의 정기 예금 마케팅 캠페인 성공 예측
- 특수 상황: 글로벌 금융위기 시기 데이터 (2008년 서브프라임 모기지 사태 ~ 유럽 재정위기)

2.3 고객 기본 정보 (Bank Client Data)

- age: 나이 (숫자형) - 고객의 연령대별 금융 성향 분석 가능
- job: 직업 (범주형) - 소득 수준 및 직업 안정성 추정 지표
    - 12개 카테고리: admin, blue-collar, entrepreneur, housemaid, management, retired, self-employed, services, student, technician, unemployed, unknown
- marital: 결혼 여부 (범주형) - 가족 구성 및 금융 책임 수준 추정
- education: 교육 수준 (범주형) - 소득 수준 및 금융 이해도 추정 지표
    - basic.4y, basic.6y, basic.9y, high.school, illiterate, professional.course, university.degree, unknown

2.4 신용 상태 관련 (Credit Information)

- default: 신용 불량 여부 (범주형) - 가장 직접적인 신용 위험 지표
- housing: 주택 대출 여부 (범주형) - 상대적으로 안정적인 대출 형태
- loan: 개인 대출 여부 (범주형) - 상대적으로 위험도 높은 대출 형태

2.5 캠페인 관련 (Campaign Information)

- contact: 연락 방식 (범주형) - cellular vs telephone 효과 분석 가능
- month: 마지막 연락 월 (범주형) - 계절별/월별 마케팅 효과 분석
- day_of_week: 마지막 연락 요일 (범주형) - 요일별 연락 효과 분석
- duration: 통화 지속 시간 초 단위 (숫자형)
    - 제외: 실무 예측 모델에서 반드시 제외 (통화 후에만 알 수 있는 정보로 실제 예측에 사용 불가)
- campaign: 현재 캠페인 연락 횟수 (숫자형) - 고객 피로도 분석 지표
- pdays: 이전 캠페인 후 경과 일수 (숫자형) - 999는 이전 캠페인 없음을 의미
- previous: 이전 캠페인 연락 횟수 (숫자형)
- poutcome: 이전 캠페인 결과 (범주형) - failure, nonexistent, success

2.6 거시경제 지표 (Social and Economic Context) 주의: 개별 고객 경제력이 아닌 전체 경제환경 지표

- emp.var.rate: 고용 변동률 (분기별 지표) - 경제 안정성 지표
- cons.price.idx: 소비자 물가지수 (월별 지표) - 구매력 지표
- cons.conf.idx: 소비자 신뢰지수 (월별 지표) - 경제 심리 지표
- euribor3m: 3개월 유리보 금리 (일별 지표) - 자금 조달 비용
- nr.employed: 고용자 수 (분기별 지표) - 경제 규모 지표

2.7 타겟 변수

- y: 정기 예금 가입 여부 (이진 분류) - "yes" 또는 "no"

3.데이터 특성 및 주의사항

3.1 결측치 처리 방안

- 범주형 데이터의 결측치는 "unknown" 라벨로 표시됨
- 이를 별도 카테고리로 처리할지, 다른 방법으로 대체할지 결정 필요

3.2 Duration 변수 처리 전략

- 모든 모델에서 duration 변수 제외: 실무적으로 예측 시점에 알 수 없는 정보이므로 무조건 제거
- 통화 시간은 결과 분석용으로만 활용 (모델 성능 평가에는 사용하지 않음)

3.3 시간적 특성 및 금융위기 맥락

- 데이터가 시간순으로 정렬되어 있어 시계열 분석 가능
- 2008-2010년 글로벌 금융위기 시기:
    - 경제불안정, 높은 실업률, 신용경색 상황
    - 고객들의 위험회피 성향 증가로 안전자산(정기예금) 선호도 변화
    - 은행의 자금조달 어려움과 예금 확보 필요성 증대
- 거시경제 지표의 중요성: 금융위기 상황에서 경제지표가 고객 행동에 미치는 영향 극대화

- 캠페인 전략의 시대적 배경: 불안정한 경제상황에서의 마케팅 전략 효과성 분석 가능

---

4. 데이터 탐색 및 변수 분석

4.1 타겟 분포 및 불균형

포르투갈 은행 마케팅 데이터는 정기예금 가입률이 약 11% 수준으로, 타겟 불균형이 심한 이진 분류 문제입니다.

```
1. 타겟 변수 (y) 분포
------------------------------
정기예금 가입 현황:
  no: 36,548명 (88.7%)
  yes: 4,640명 (11.3%)
```

4.2 주요 변수별 분포 및 특성

숫자형 변수(나이, 연락 횟수 등)와 범주형 변수(직업, 교육 수준 등)에 대한 히스토그램과 박스플롯 등을 활용하여 분포와 이상 값을 분석하였습니다.

예를 들어, campaign 변수는 3~4회에서 가입률이 가장 높으며, 20회를 초과할 경우 오히려 가입률이 하락하는 피로도 효과가 관찰됩니다.

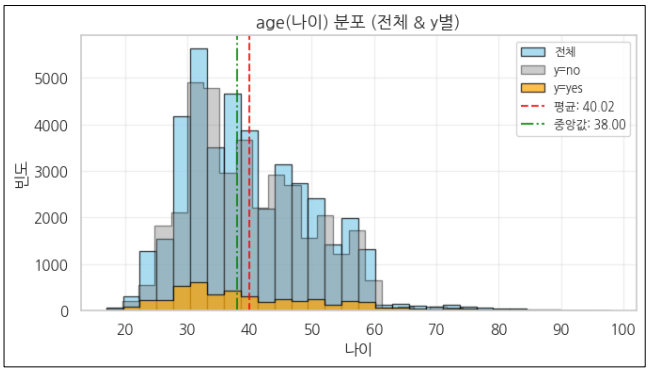

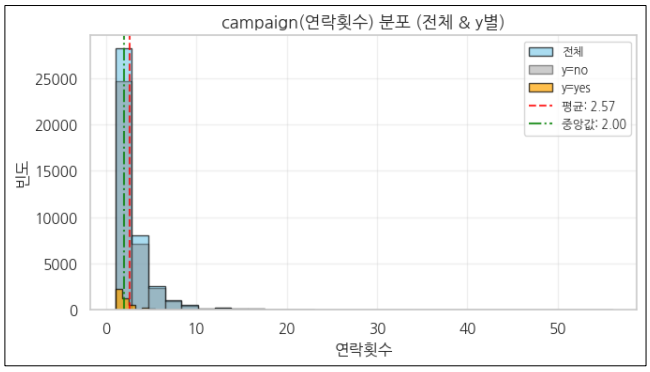

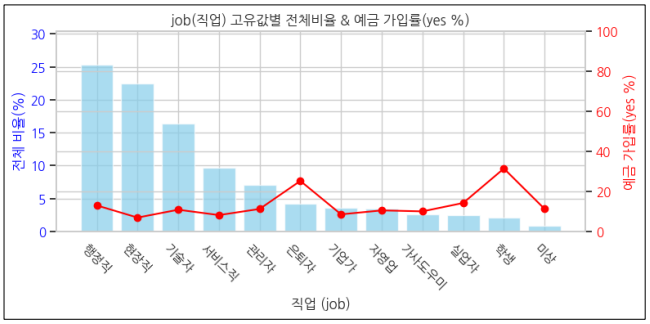

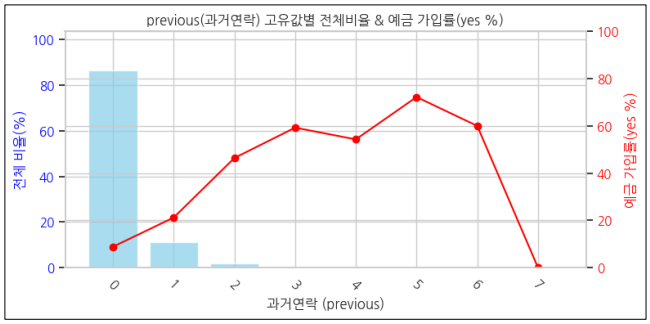

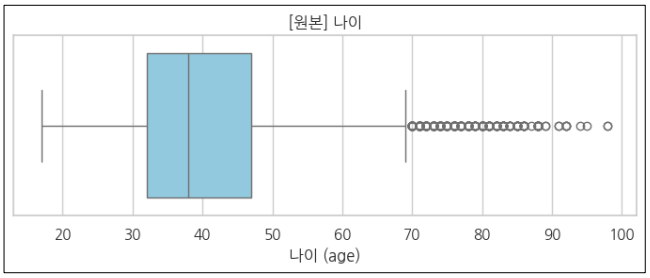

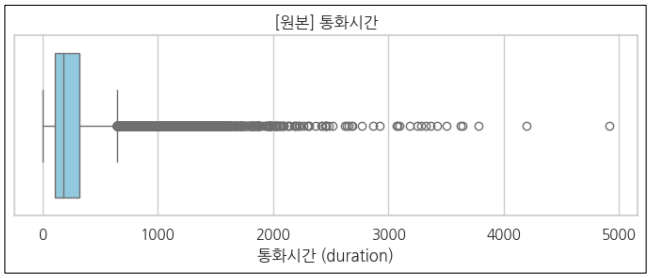

4.3 거시경제 지표 및 가입률 추이

고용률, 유리보금리, 소비자 신뢰지수, 물가지수 등 거시경제 변수와 예금 가입률 간의 시계열 추이를 분석한 결과, 경기 침체 또는 금리 인하 시기에 예금 가입률이 상승하는 현상을 확인할 수

있었습니다. 이는 'Precautionary savings(예방적 저축)' 현상으로 해석됩니다. 그리고 일정 한계를 넘으면 'Liquidity Constraint(유동성 제약) 현상이 발생하는 것으로 해석됩니다.

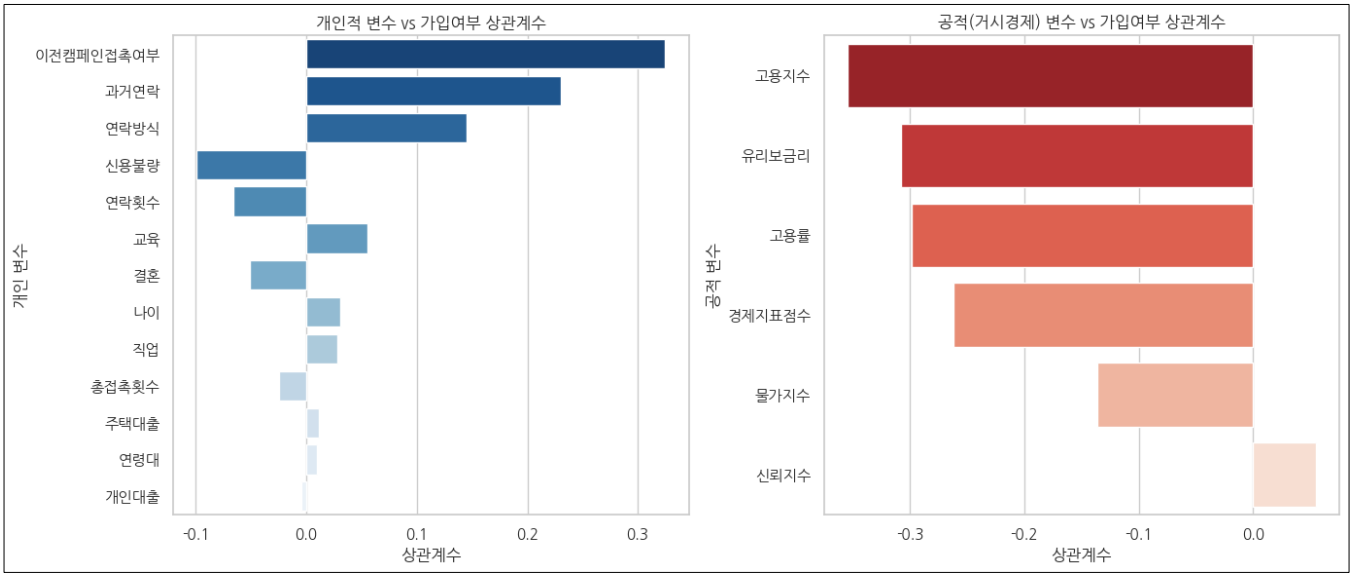

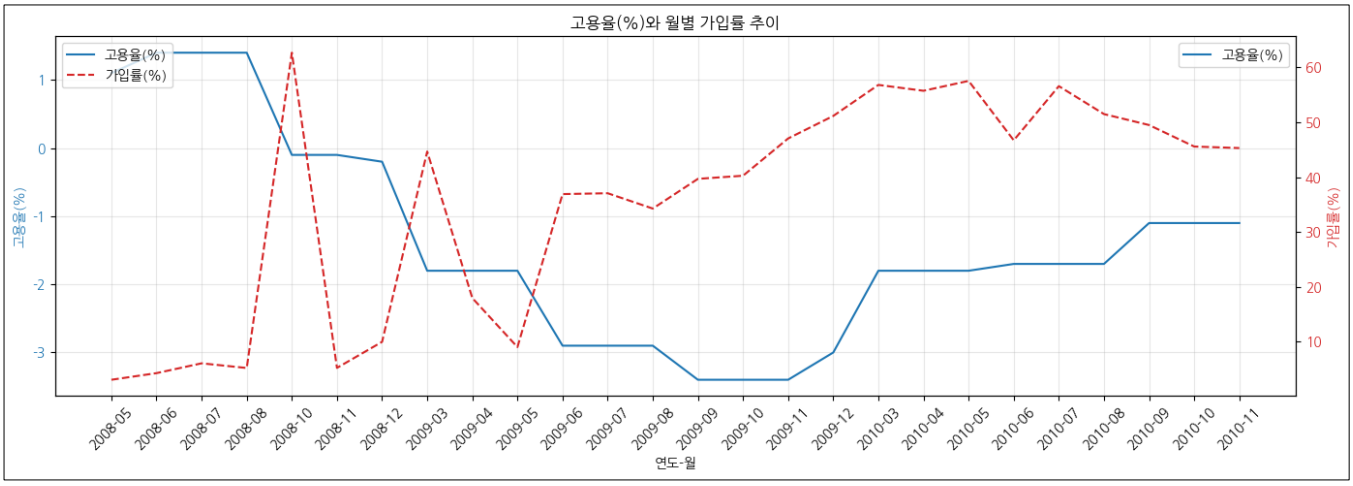

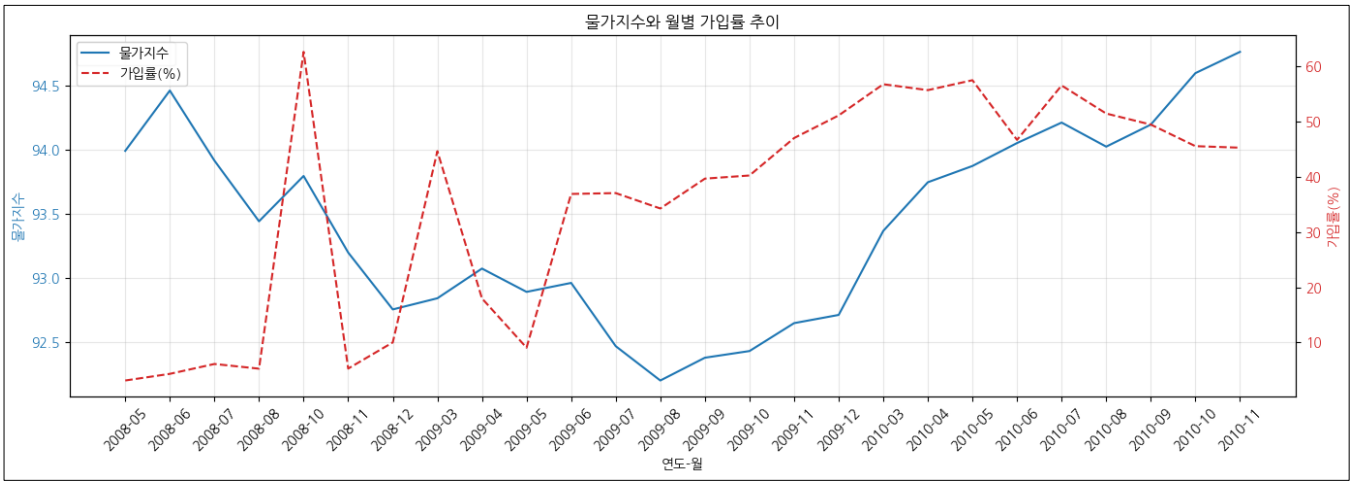

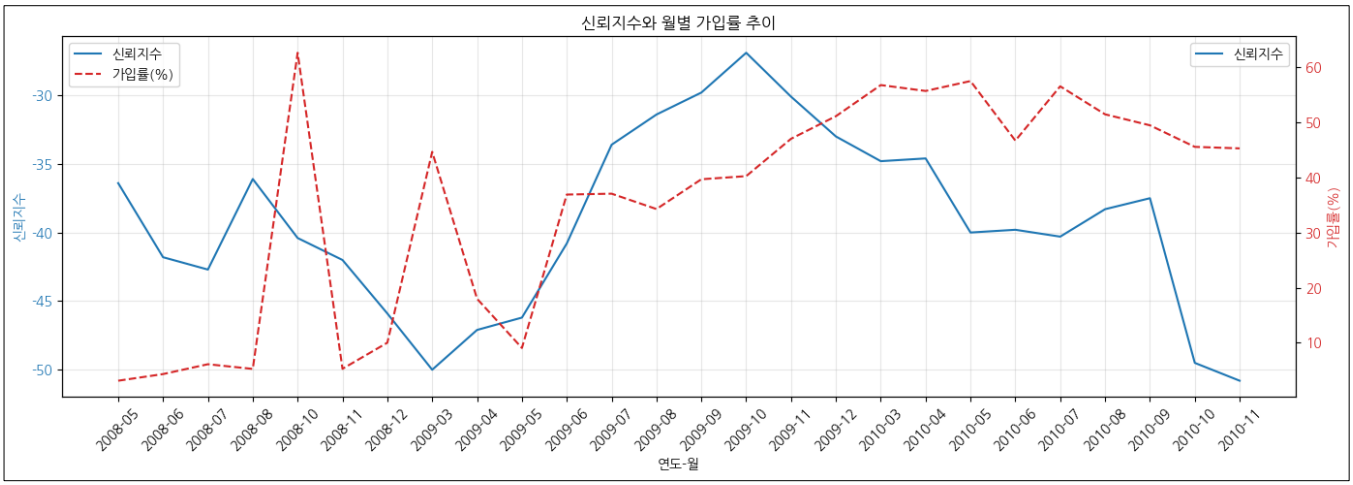

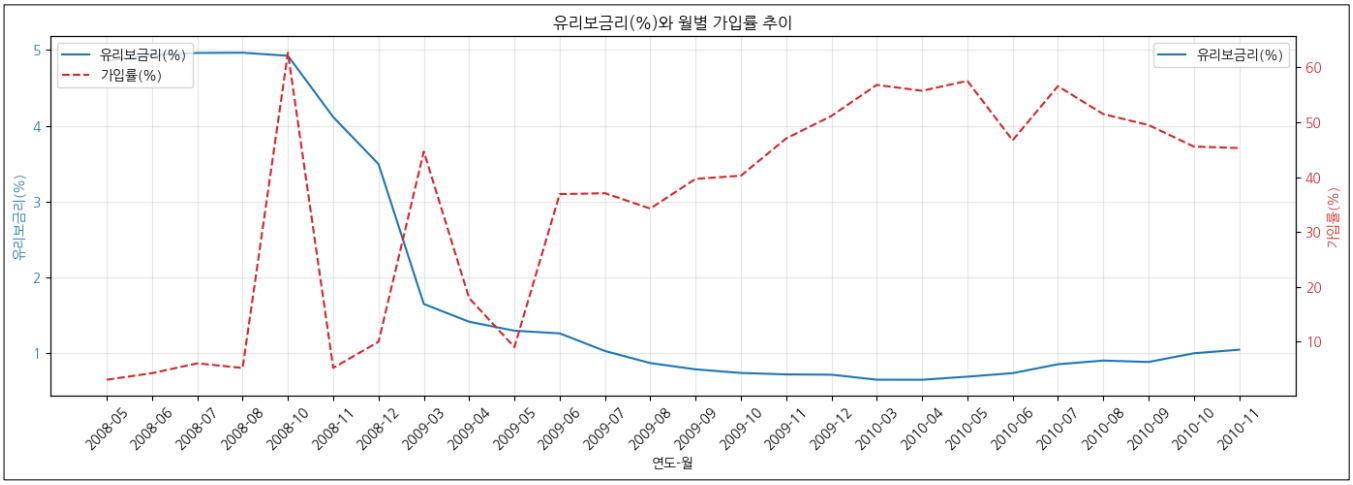

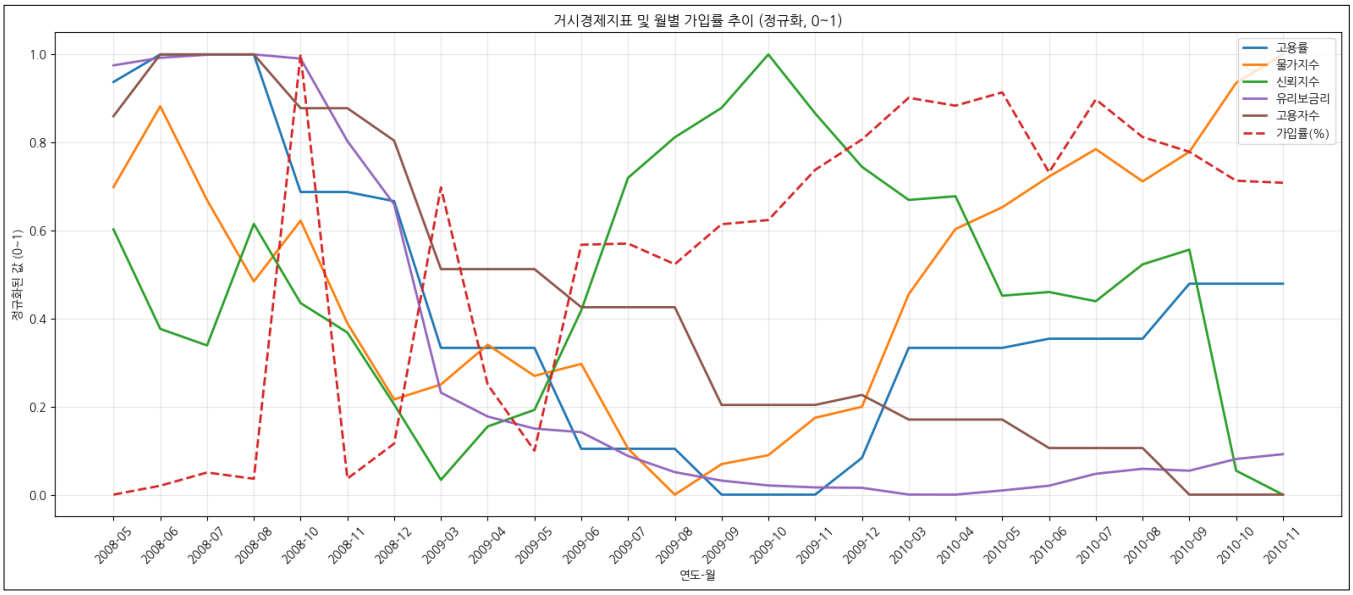

4.4 변수별 가입률/상관관계 분석

범주형 변수(직업, 교육, 개인대출 등)별로 가입률을 비교하고, 각 변수와 타겟(y) 간의 상관관계를 수치 및 그래프로 정리하였습니다. 예컨대 고학력, 고신용, 고소득군에서 예금 가입률 분석, 과거 캠페인 성공 경험(poutcome=success)이 있는 고객의 재가입률이 월등히 높았습니다.

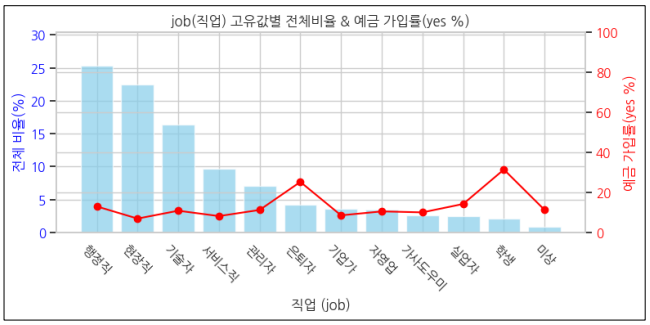

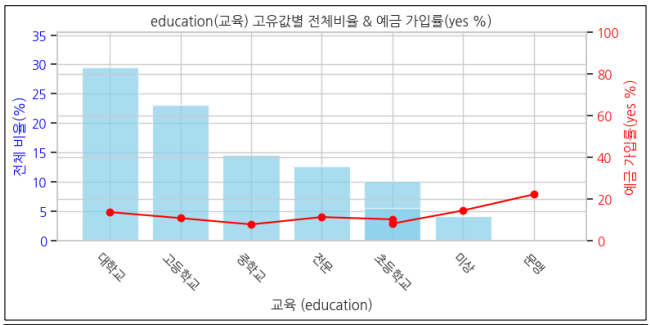

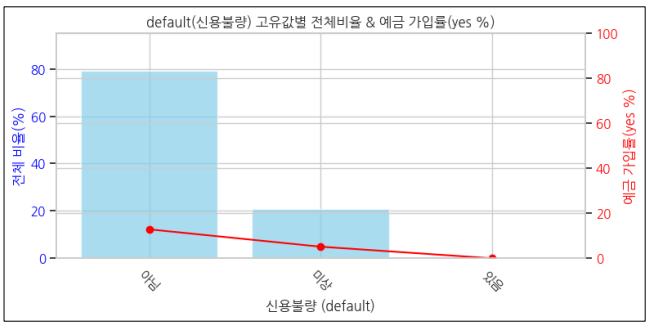

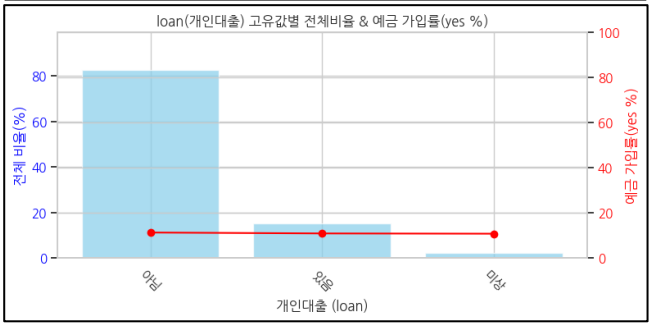

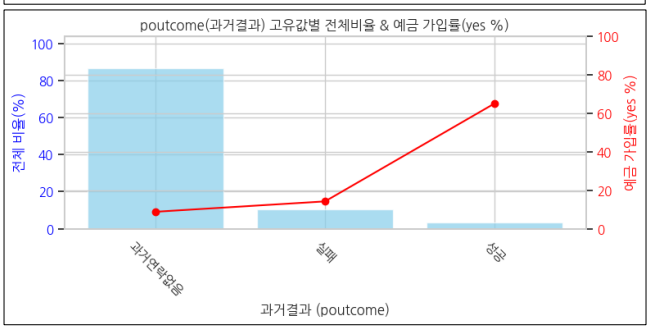

---

5. 데이터 전처리

5.1 pdays 처리

- pdays는 접촉 여부로만 판단하는 파생 변수를 만들고 pdays는 사용 안함
- 분포를 살펴 봤을 때 접촉 여부 판단만 하더라도 될 것으로 판단함
    - pdays_contacted_before

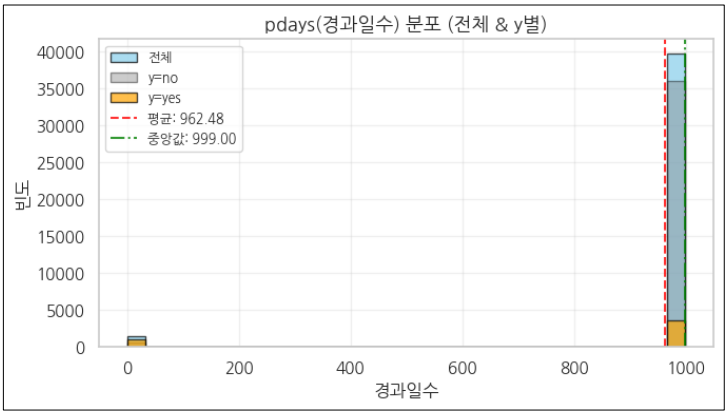

5.2 인코딩(라벨/순서형/비즈니스 논리)된 변수

변수명	인코딩	의미 및 방식 요약
job	인코딩	직업별 소득/안정성 순서형 인코딩 (0~10)
marital	인코딩	결혼상태별 경제적 안정도 순서형 인코딩 (0~2)
education	인코딩	교육수준별 순서형 인코딩 (0~5)
default	인코딩	신용불량 여부: no(-1), unknown(0), yes(1)
housing	인코딩	주택대출 여부: no(-1), unknown(0), yes(1)
loan	인코딩	개인대출 여부: no(-1), unknown(0), yes(1)
contact	인코딩	연락방식: telephone(0), cellular(1)

변수명	인코딩	의미 및 방식 요약
month	인코딩	월별 순서형 인코딩 (0~11)
day_of_week	인코딩	요일별 순서형 인코딩 (0~6)
poutcome	인코딩	과거 캠페인 결과: failure(0), nonexistent(1), success(2)
y	타겟 인코딩	정기예금 가입여부: no(0), yes(1)
age_group	라벨 인코딩	연령대 그룹: young(0), adult(1), middle(2), senior(3), elderly(4)

5.3 스케일링된 변수

변수명	스케일링	의미 및 방식 요약
age_scaled	StandardScaler	나이 표준화
emp.var.rate_scaled	StandardScaler	고용률 표준화
cons.price.idx_scaled	StandardScaler	물가지수 표준화
cons.conf.idx_scaled	StandardScaler	신뢰지수 표준화
euribor3m_scaled	StandardScaler	유리보금리 표준화
nr.employed_scaled	StandardScaler	고용지수 표준화
campaign_scaled	MinMaxScaler	현재 캠페인 연락횟수 0~1 정규화
previous_scaled	MinMaxScaler	과거 캠페인 연락횟수 0~1 정규화
pdays_scaled	MinMaxScaler	pdays(이전 캠페인 접촉일수) 0~1 정규화 (999→0)

5.4 추가된 파생 변수 및 의미

변수명	의미 및 산출 방식
economic_score	개별 고객 경제력 점수 (직업, 교육, 나이, 결혼상태 점수화 합산)
economic_grade	economic_score 등급화 (상/중상/중/중하/하)
credit_score	신용점수 (default, housing, loan 점수화 합산)
credit_grade	credit_score 등급화 (A~E)
year_month	연락 시점의 연-월(YYYY-MM)
emp.var.rate_chg_pct/diff	고용률 전월 대비 변화율/차이
cons.price.idx_chg_pct/diff	물가지수 전월 대비 변화율/차이
cons.conf.idx_chg_pct/diff	신뢰지수 전월 대비 변화율/차이
euribor3m_chg_pct/diff	유리보금리 전월 대비 변화율/차이
nr.employed_chg_pct/diff	고용지수 전월 대비 변화율/차이
is_high_risk	고위험군 여부 (신용등급 E 또는 경제점수 하위 20%)
pdays_contacted_before	이전 캠페인 접촉 경험 여부 (pdays!=999:1, 999:0)
is_existing_customer	기존 고객 여부 (pdays_contacted_before와 동일)
age_group	나이 구간별 그룹화 (young, adult, middle, senior, elderly)
total_contacts	총 접촉 횟수 (campaign + previous)
economic_score (거시경제)	5개 경제지표 스케일링 후 평균값 (거시경제 환경 종합점수)

---

6. 모델링 및 하이퍼파라미터 튜닝

6.1 실험 설계

- 데이터 분할: train/test(8:2), stratify로 타겟 분포 유지
- 평가 지표: F1, ROC-AUC, Precision, Recall, Accuracy 등 종합 고려

6.2 모델별 함수 및 하이퍼파라미터

결정트리, 랜덤포레스트, 그래디언트 부스팅, XGBoost 등 다양한 분류 모델을 적용하고, 주요 하이퍼파라미터(트리 깊이, 노드 수, 학습률 등)를 그리드로 정의하여 자동 탐색.

부록 1: 하이퍼파라미터

```
모델링 단계로 진행합니다...
시스템 정보:
  CPU 코어 수: 16
  가용 메모리: 15.0GB
  총 메모리: 31.7GB
  권장 n_jobs: -1 (모든 코어 사용)
```

```
성능 설정 완료
   병렬 처리: -1 코어 활용
   NumPy : 활성화

메모리 중...
   전: 13.04MB
   후: 6.91MB
   절약된 메모리: 6.13MB (47.0%)
   가비지 컬렉션 완료
================================================
=== 모든 하이퍼파라미터 조합 생성 ===
Decision Tree: 27개 조합 생성 (모든 조합)
Random Forest: 81개 조합 생성 (모든 조합)
Gradient Boosting: 324개 조합 생성 (모든 조합)
XGBoost: 216개 조합 생성 (모든 조합)
총 648개 조합

조합 수 검증:
Decision Tree: 27 (계산) = 27 (실제) ✓
Random Forest: 81 (계산) = 81 (실제) ✓
Gradient Boosting: 324 (계산) = 324 (실제) ✓
XGBoost: 216 (계산) = 216 (실제) ✓
```

6.3 하이퍼파라미터 자동 탐색

모든 모델별로 주요 하이퍼파라미터 조합을 반복 실행하며, 캐시 및 시스템 리소스를 효율적으로 활용.

```
=== 최적 파라미터 기반 Voting Classifier 구성 ===
각 모델별 최적 성능:
Decision Tree: F1=0.4747, 파라미터조합=#1
Gradient Boosting: F1=0.5172, 파라미터조합=#205
Random Forest: F1=0.5291, 파라미터조합=#68
XGBoost: F1=0.5086, 파라미터조합=#102

Decision Tree 최적 파라미터:
  {'max_depth': 4, 'min_samples_split': 30, 'min_samples_leaf': 5, 'criterion': 'gini', 'max_features': 'None'}

Gradient Boosting 최적 파라미터:
  {'n_estimators': 200, 'learning_rate': 0.01, 'max_depth': 8, 'min_samples_split': 50, 'min_samples_leaf': 10, 'subsample': 0.1}

Random Forest 최적 파라미터:
  {'n_estimators': 150, 'max_depth': 15, 'min_samples_split': 20, 'min_samples_leaf': 3, 'max_features': 'sqrt', 'bootstrap':
True}

XGBoost 최적 파라미터:
  {'n_estimators': 200, 'learning_rate': 0.01, 'max_depth': 8, 'min_child_weight': 5, 'subsample': 0.8, 'colsample_bytree': 1.0,
'reg_alpha': 0.1, 'reg_lambda': 2.0}
캐시된 Hard Voting 결과를 사용합니다.
캐시된 Soft Voting 결과를 사용합니다.

최종 성능 비교표:
               Model     Type F1-Score ROC-AUC Precision Recall Accuracy Train_Time
 0     Decision Tree 개별모델   0.4747  0.7962    0.3856 0.6175   0.8461      0.15s
 1 Gradient Boosting 개별모델   0.5172  0.8108    0.4368 0.6336   0.8667      6.70s
 2     Random Forest 개별모델   0.5291  0.8123    0.4598 0.6228   0.8751      7.41s
 3           XGBoost 개별모델   0.5086  0.8175    0.4224 0.6390   0.8609      1.78s
 4       Hard Voting   앙상블   0.5252  0.7511    0.4779 0.5830   0.8813     14.92s
 5       Soft Voting   앙상블   0.5286  0.8155    0.4770 0.5927   0.8809     14.45s
```

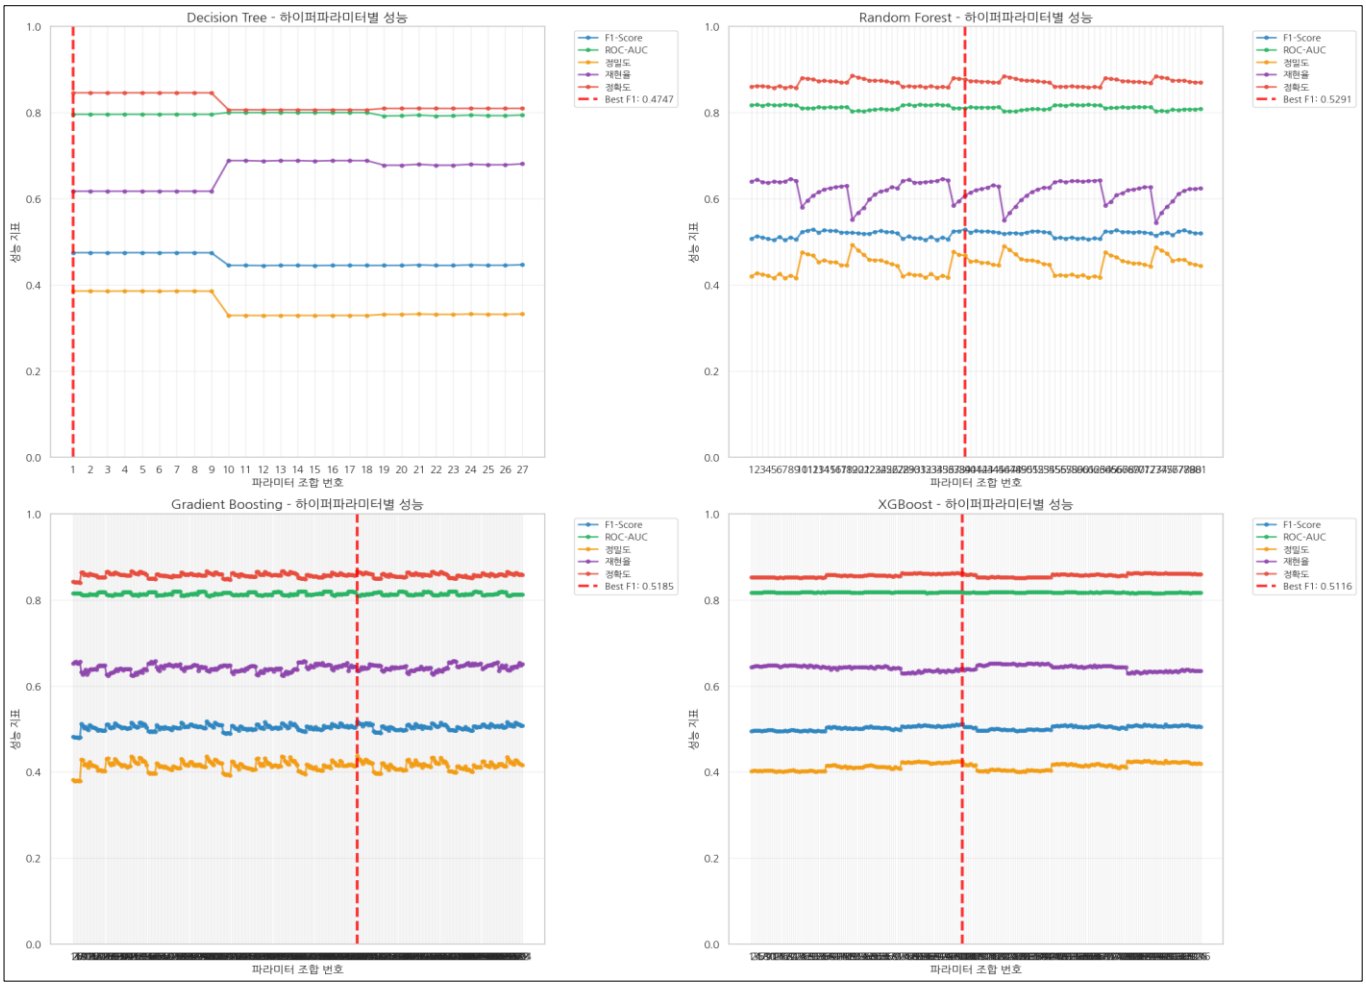
Decision Tree - 하이퍼파라미터별 성능
Random Forest - 하이퍼파라미터별 성능
Gradient Boosting - 하이퍼파라미터별 성능
XGBoost - 하이퍼파라미터별 성능
F1-Score
ROC-AUC
정밀도
재현율
정확도
Best F1: 0.4747
Best F1: 0.5291
Best F1: 0.5185
Best F1: 0.5116
성능 지표
파라미터 조합 번호

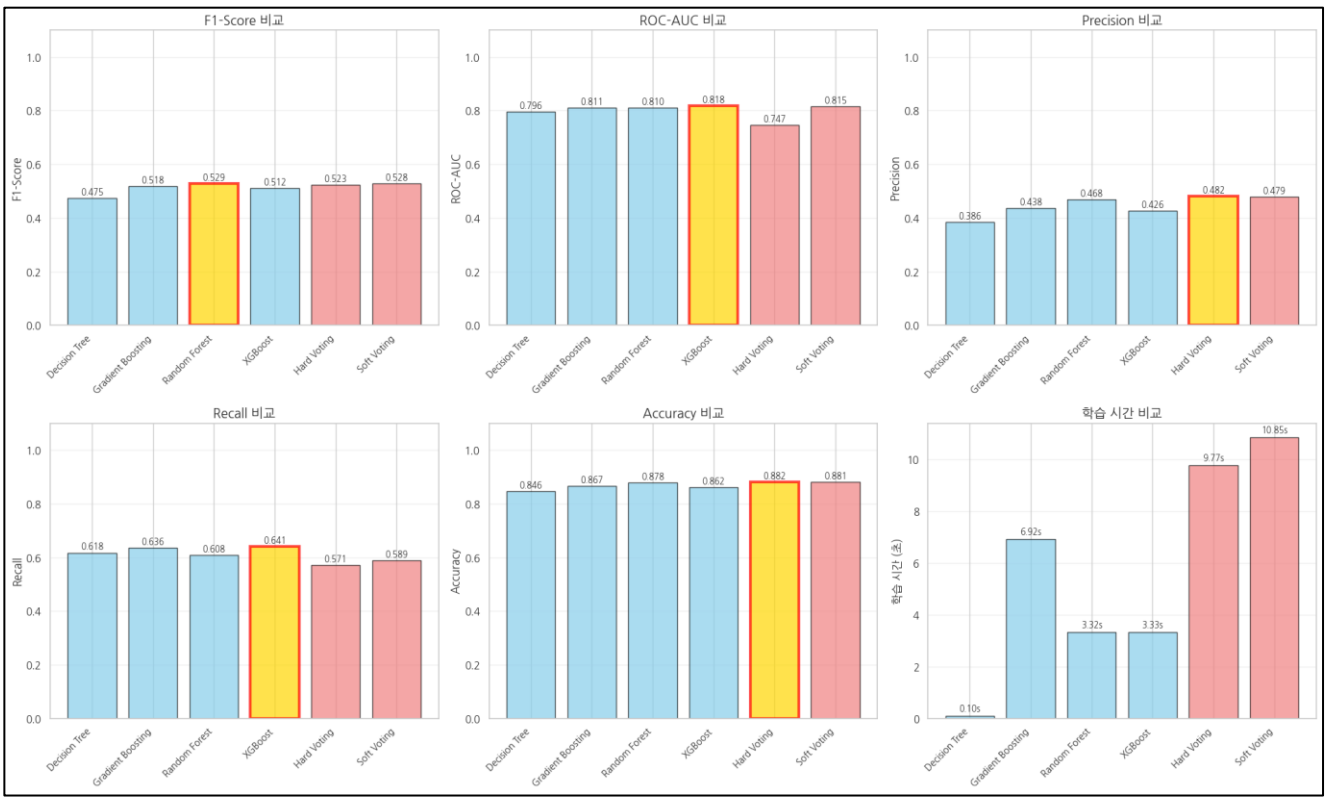
F1-Score 비교
ROC-AUC 비교
Precision 비교
Recall 비교
Accuracy 비교
학습 시간 비교
F1-Score
ROC-AUC
Precision
Recall
Accuracy
학습 시간 (초)
0.475
0.518
0.529
0.512
0.523
0.528
0.796
0.811
0.810
0.818
0.747
0.815
0.386
0.438
0.468
0.426
0.482
0.479
0.618
0.636
0.608
0.641
0.571
0.589
0.846
0.867
0.878
0.862
0.882
0.881
0.10s
6.92s
3.32s
3.33s
9.77s
10.85s
Decision Tree
Gradient Boosting
Random Forest
XGBoost
Hard Voting
Soft Voting

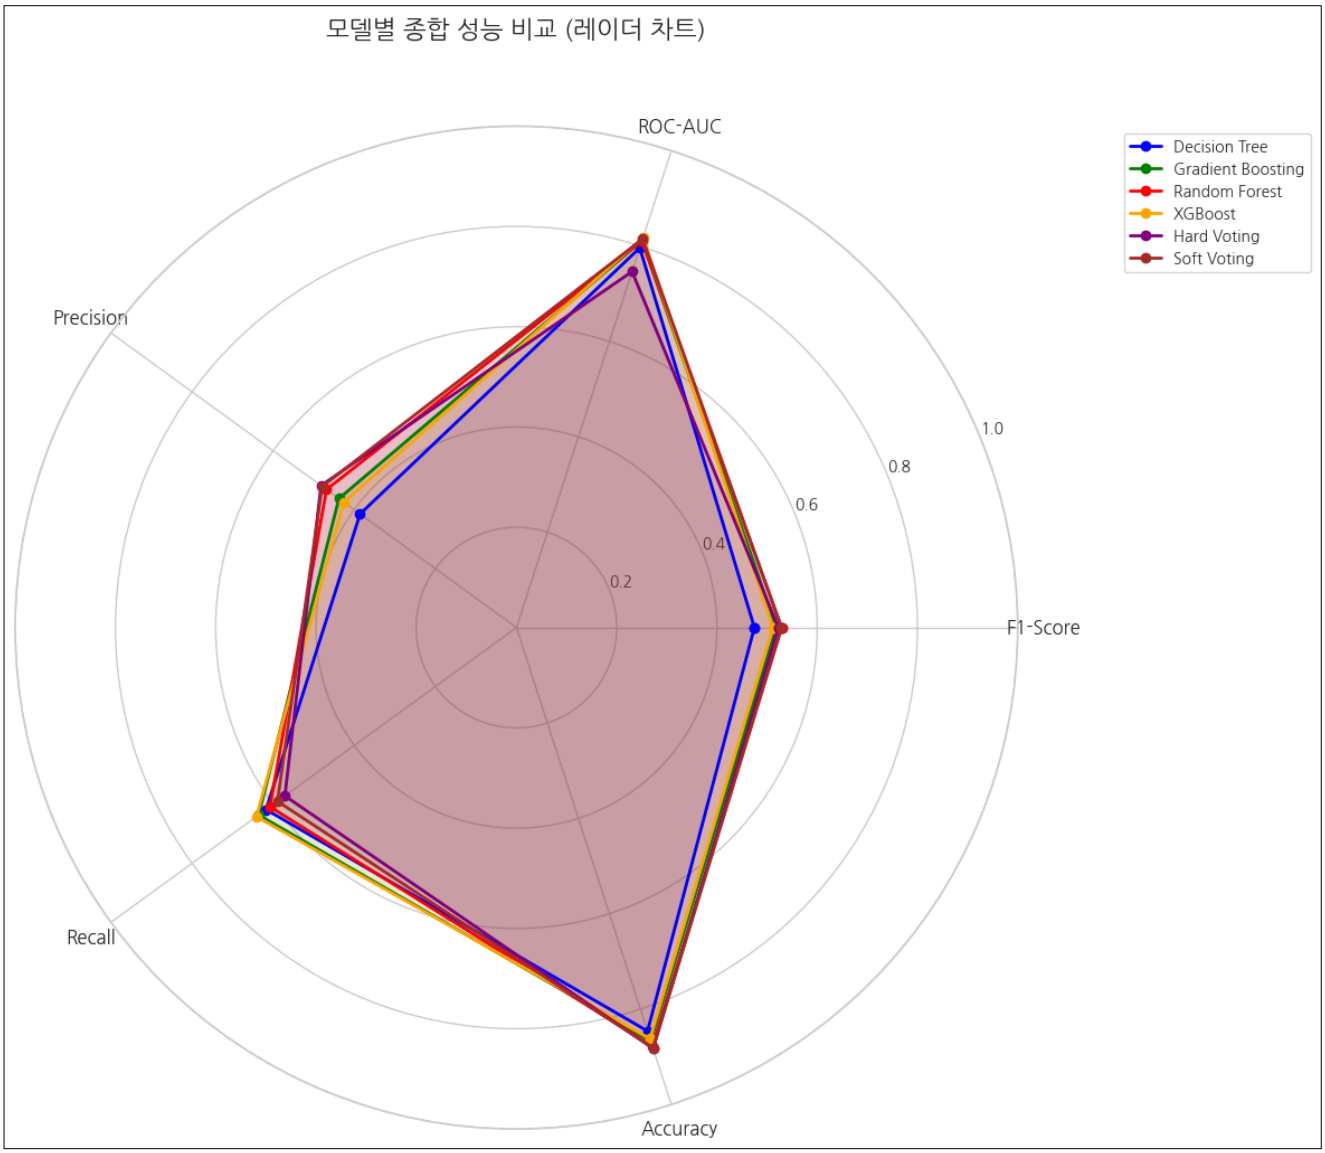

6.4 결과 요약 및 비교

- 앙상블 모델(랜덤포레스트, XGBoost, Voting)이 단일 모델(결정트리 등) 대비 일관적으로 우수한 성능을 보임
- 불균형 데이터 상황에서 F1 Score, ROC-AUC 등에서 앙상블 모델의 강점이 부각됨

---

7. 모델 해석 및 비즈니스 인사이트

7.1 변수 중요도 분석

- economic_score, credit_grade, poutcome(과거 캠페인 결과), emp.var.rate(고용률), age, campaign(연락 횟수)가 변수 중요도 상위권
- 경제력 및 신용등급이 높을수록 예금 가입 확률 상승
- 과거 캠페인 성공 경험, 고용률 하락, 나이 증가, 적정 연락 횟수(3~4회)는 모두 가입률을 높이는 요인

7.2 거시경제 vs 개인 특성 영향

- 고용률, 금리 등 거시경제 변수는 가입률과 강한 음의 상관관계(경기 침체, 금리 하락 시 가입률 상승)
- 신뢰지수, 물가지수 등은 약한 양의 상관관계
- 개인 특성(경제력, 신용등급, 직업, 교육 등) 또한 예측력에 크게 기여
- 금융위기 시기에는 경제 불안 심리가 예금 선호로 이어지는 예방적 저축(Precautionary

savings) 현상 나타남

7.3 실무 적용 전략

- 가입 확률 80% 이상: 즉시 연락 및 프리미엄 상품 제안
- 50~80%: 2차 타겟, 맞춤형 혜택 제공
- 30~50%: 정보성 캠페인 위주 접근
- 30% 미만: 캠페인 대상에서 제외하여 비용 최소화
- 고위험군(신용등급 E, 경제점수 하위 20%): 리스크 관리와 신중한 접근
- 적정 연락 횟수(3~4회)는 긍정적, 과도한 연락은 오히려 역효과

7.3.1 소스코드

```
# 1. 테스트 데이터에 대해 가입 확률 예측
best_model = voting_soft  # 또는 원하는 모델(best_xgb 등)
y_pred_proba = best_model.predict_proba(X_test)[:, 1]  # 가입 확률 (1 클래스)

# 2. 확률 구간별 그룹 분류
def assign_group(prob):
    if prob >= 0.8:
        return "즉시 연락/프리미엄"
    elif prob >= 0.5:
        return "2차 타겟/맞춤혜택"
    elif prob >= 0.3:
        return "정보성 캠페인"
    else:
        return "캠페인 제외"

group_labels = [assign_group(p) for p in y_pred_proba]

# 3. 결과 데이터프레임 생성
result_df = X_test.copy()
result_df['가입확률'] = y_pred_proba
result_df['마케팅그룹'] = group_labels

# 4. 그룹별 인원 및 비율 확인
group_summary = result_df['마케팅그룹'].value_counts(normalize=True).mul(100).round(2)
print("마케팅 그룹별 분포(%)")
#print(group_summary)
group_summary.head_att()

print()
# 5. 예시 상위 10명 출력
result_df_sorted = result_df.sort_values('가입확률', ascending=False)
result_df_sorted[['가입확률', '마케팅그룹']].head_att(10)
#print(result_df_sorted[['가입확률', '마케팅그룹']].head())
```

7.3.2 결과

```
마케팅 그룹별 분포(%)
인덱스              proportion
index              proportion
캠페인 제외         74.29
정보성 캠페인       11.85
2차 타겟/맞춤혜택   11.79
즉시 연락/프리미엄  2.08

       가입확률         마케팅그룹
       가입확률         마케팅그룹
 39655   0.9123 즉시 연락/프리미엄
 40476   0.9074 즉시 연락/프리미엄
 40487   0.9062 즉시 연락/프리미엄
```

```
 40360    0.906 즉시 연락/프리미엄
 40473    0.904 즉시 연락/프리미엄
 40413   0.9036 즉시 연락/프리미엄
 40586   0.9031 즉시 연락/프리미엄
 40163   0.9012 즉시 연락/프리미엄
 39498    0.901 즉시 연락/프리미엄
 39644   0.9008 즉시 연락/프리미엄
```

7.3.4 해석

상위 10명의 가입확률이 모두 0.90 이상으로, 이들은 '즉시 연락/프리미엄' 그룹에 속합니다.
즉, 모델이 예측한 가입 확률이 매우 높은 고객을 잘 선별 해냈음을 보여줍니다.
전체 분포를 보면:

캠페인 제외(가입확률 0.3 미만): 73.89% (대부분의 고객은 가입 가능성이 낮음)
즉시 연락/프리미엄(0.8 이상): 2.09% (가입 가능성이 매우 높은 핵심 타겟)
2차 타겟/맞춤혜택(0.5~0.8): 11.8%
정보성 캠페인(0.3~0.5): 12.22%

7.3.5 해석 결론

가입확률이 높은 고객(상위 2%)을 효과적으로 분류하고 있음.
실제 마케팅에서 즉시 연락/프리미엄 그룹을 우선적으로 공략하면 높은 성공률을 기대.
반대로, '캠페인 제외' 그룹은 마케팅 효율을 위해 제외하는 것이 합리적.
즉, 모델이 가입 확률이 높은 고객을 잘 구분해주고 있다는 의미입니다.

---

8. 결론

- 불균형 데이터 환경에서 앙상블 모델(랜덤포레스트, XGBoost, Voting)이 가장 우수한 성능을 기록함
- 거시경제 지표와 개인 특성 모두 예측에 유의미한 영향력을 미침
- 파생 변수와 Conservative 인코딩 기법이 모델 해석력 및 성능에 기여함
- 금융위기 시기 예금 가입의 결정요인은 경제 불안 심리에 기인한 예방적 저축 현상임이 확인됨
- 외부 변수(가구소득, 지역, 경쟁사 정보 등)가 미포함된 한계와, 실전 적용을 위한 추가 실험 필요성 있음.

---

9. 교훈

- 하이퍼파라미터 탐색 시 너무 많은 조합을 하면 시간이 오래 걸림
    - 좁은 범위를 블럭 단위로 좁혀 가는 것이 효율 적임
- 분석을 위한 jupyter notebook을 사용시 프로그램을 잘 구분할 것
- 불필요한 파생 인자를 생성하지 말 것

✧ 참고 문헌

Leland, H. E. (1968). Saving and Uncertainty: The Precautionary Demand for Saving
(예방적 저축의 개념을 처음으로 정립한 논문 AI 검색)

10.부록

부록 1: 하이퍼파라미터

연구 완료일: 2025년 7월 30일 ¦ 연구자: 김명환 (5팀) ¦ 소속: AI 4기 5팀 스프린트 미션 4

부록 1: 하이퍼파라미터

```
def create_hyperparameter_test2():
    """
    모든 하이퍼파라미터 조합을 생성하는 함수
    각 모델별로 실제 가능한 모든 조합을 for문으로 생성
    """
    import itertools

    print("=== 모든 하이퍼파라미터 조합 생성 ===")

    dt_param_grid = []

    # 1. Decision Tree

    dt_max_depths = [4, 5, 6]
    dt_min_samples_splits = [30, 20, 40]
    dt_min_samples_leafs = [5, 10, 15]
    #dt_criterions = ['gini', 'entropy']
    dt_criterions = ['gini']
    # 은행의 텔레마케팅은 랜덤 방식으로 진행된다.
    # 랜덤 방식에 적합한 gini가 더 적합할 것으로 판단된다.

    #dt_max_features_list = [None, 'sqrt', 'log2']
    dt_max_features_list = [None]
    # 현재 y 성공율이 11% 정도로 특성을 고려하기 보다는
    # 모든 특성을 검토하자 None

    for max_depth in dt_max_depths:
        for min_samples_split in dt_min_samples_splits:
            for min_samples_leaf in dt_min_samples_leafs:
                for criterion in dt_criterions:
                    for max_features in dt_max_features_list:
                        dt_param_grid.append({
                            'max_depth': max_depth,
                            'min_samples_split': min_samples_split,
                            'min_samples_leaf': min_samples_leaf,
                            'criterion': criterion,
                            'max_features': max_features
                        })


    # 2. Random Forest
    rf_param_grid = []

    rf_n_estimators_list = [95, 100, 150]
    rf_max_depths = [10, 15, 20]
    rf_min_samples_splits = [10, 20, 30]
    # 현재 11%로 편향이 심한 데이터로
    # min_samples_split을 낮게 설정하여 세밀한 분할 이 필요 하다.

    rf_min_samples_leafs = [2, 3, 4]
    # 현재 11%로 편향이 심한 불균형 데이터 전반적인 검사를 해야 함.

    # rf_max_features = ['sqrt', 'log2', None]
    rf_max_features = ['sqrt']
    # 현재 y 성공율이 11% 정도로 특성을 고려하기 보다는
    # 모든 특성을 검토하자 None
```

```
# 모든 조합 생성
for n_estimators in rf_n_estimators_list:
    for max_depth in rf_max_depths:
        for min_samples_split in rf_min_samples_splits:
            for min_samples_leaf in rf_min_samples_leafs:
                for max_features in rf_max_features:
                    rf_param_grid.append({
                        'n_estimators': n_estimators,
                        'max_depth': max_depth,
                        'min_samples_split': min_samples_split,
                        'min_samples_leaf': min_samples_leaf,
                        'max_features': max_features,
                        'bootstrap': True
                    })

# 3. Gradient Boosting
gb_param_grid = []

# 각 파라미터의 가능한 값들 정의
gb_n_estimators = [150, 200, 250]
# 일단 colab에서 실행할 것이니 값을 낮게 설정

gb_learning_rates = [0.005, 0.010]
# 현재 y 성공율이 11% 정도로 편향이 심한 데이터로
# 학습률을 낮게 설정하여 세밀한 학습이 필요 하다.

gb_max_depths = [6, 7, 8]
# 과적합 방지를 위해서는 많은 것이 좋으나 (현실적 11% 마케팅)
# 추후 성공률 비교를 위하여 높은 깊은 값도 추가

gb_subsamples = [0.8, 0.1, 0.15]
# 11%는 반대로 89%의 실패를 분류해도 성공 분류가 되어 버린다.
# 따라서 샘플링 비율을 낮추어 실패를 더 많이 포함시킨다.
# 현재 y 성공율이 11% 정도로 편향이 심한 데이터로
# 샘플링 비율을 낮게 설정하여 세밀한 학습이 필요 하다.

gb_min_samples_splits = [50, 100]
# 50: 가입 고객의 세밀한 패턴까지 포착 시도
# 100: 실무에서 가장 무난한 선택
# 150: 오버피팅 방지 및 일반화 성능 확보
# 테스트 결과를 보고 결정하자

gb_min_samples_leafs = [10, 20, 30]
# 현재 데이타 베이스 규모 검토

# 모든 조합 생성
for n_estimators in gb_n_estimators:
    for learning_rate in gb_learning_rates:
        for max_depth in gb_max_depths:
            for subsample in gb_subsamples:
                for min_samples_split in gb_min_samples_splits:
                    for min_samples_leaf in gb_min_samples_leafs:
                        gb_param_grid.append({
                            'n_estimators': n_estimators,
                            'learning_rate': learning_rate,
                            'max_depth': max_depth,
                            'subsample': subsample,
                            'min_samples_split': min_samples_split,
                            'min_samples_leaf': min_samples_leaf
                        })

# 4. XGBoost 파라미터 조합 (모든 조합 생성)
xgb_param_grid = []
```

```
# 각 파라미터의 가능한 값들 정의
xgb_n_estimators = [200, 300]
# 소규모 데이터 (< 10,000행): 50-200
# 중규모 데이터 (10,000-100,000행): 100-500
# 대규모 데이터 (> 100,000행): 200-1000+
# 데이타는 중규모이나 11% 정도로 편향이 심한 데이터로
# 학습 시간이 길어지므로 50-150 정도로 설정

xgb_learning_rates = [0.01]
# 0.01  매우 느림   높음  낮음  500-1000+
# 0.05  느림  중간-높음   중간  200-500
# 0.1   빠름  중간  높음  100-300
# 11% 정도로 편향이 심한 데이터로
# 학습률을 낮게 설정하여 세밀한 학습이 필요 하다.

xgb_max_depths = [6, 7, 8]
#3 단순 데이터, 빠른 실험
#5 일반적 사용, 균형
#7 복잡 데이터, 정밀 분석
# 시험을 위하여 고르게 시험

xgb_min_child_weights = [3, 5]
#1 대용량, 복잡한 패턴
#3 일반적 사용, 균형
#5 소용량, 안정성 중시
# 시험을 위하여 고르게 시험

xgb_subsamples = [0.7, 0.8, 0.9]
#실패 케이스: 89% × 0.7 = 62.3%
#성공 케이스: 11% × 0.7 = 7.7%
#실패 케이스: 89% × 0.8 = 71.2%
#성공 케이스: 11% × 0.8 = 8.8%
#실패 케이스: 89% × 0.9 = 80.1%
#성공 케이스: 11% × 0.9 = 9.9%
# 현재 y 성공율이 11% 정도로 편향이 심한 데이터로
# 샘플링 비율을 낮게 설정하여 세밀한 학습이 필요 하다.

xgb_colsample_bytrees = [1.0]
#0.7: 전체 특성의 70%만 사용 (30% 제외)
#0.8: 전체 특성의 80%만 사용 (20% 제외)
#0.9: 전체 특성의 90%만 사용 (10% 제외)

xgb_reg_alphas = [0.01, 0.1]
#0     # 정규화 없음 (기본값)
#0.01  # 약한 정규화 (과적합 약간 방지)
#0.1   # 강한 정규화 (과적합 적극 방지)

xgb_reg_lambdas = [1.0, 1.5, 2.0]
#1.0   # 기본값, 표준적인 정규화 강도
#1.5   # 더 강한 정규화 (과적합 더 적극 방지)

# 모든 조합 생성
for n_estimators in xgb_n_estimators:
    for learning_rate in xgb_learning_rates:
        for max_depth in xgb_max_depths:
            for min_child_weight in xgb_min_child_weights:
                for subsample in xgb_subsamples:
                    for colsample_bytree in xgb_colsample_bytrees:
                        for reg_alpha in xgb_reg_alphas:
                            for reg_lambda in xgb_reg_lambdas:
                                xgb_param_grid.append({
                                    'n_estimators': n_estimators,
```

```
                                        'learning_rate': learning_rate,
                                        'max_depth': max_depth,
                                        'min_child_weight': min_child_weight,
                                        'subsample': subsample,
                                        'colsample_bytree': colsample_bytree,
                                        'reg_alpha': reg_alpha,
                                        'reg_lambda': reg_lambda
                                    })

    print(f"Decision Tree: {len(dt_param_grid)}개 조합 생성 (모든 조합)")
    print(f"Random Forest: {len(rf_param_grid)}개 조합 생성 (모든 조합)")
    print(f"Gradient Boosting: {len(gb_param_grid)}개 조합 생성 (모든 조합)")
    print(f"XGBoost: {len(xgb_param_grid)}개 조합 생성 (모든 조합)")
    print(f"총 {len(dt_param_grid) + len(rf_param_grid) + len(gb_param_grid) + len(xgb_param_grid)}개 조합")

    # 예상 조합 수 계산 및 표시
    dt_expected = len(dt_max_depths) * len(dt_min_samples_splits) * len(dt_min_samples_leafs) * len(dt_criterions) *
len(dt_max_features_list)
    rf_expected = len(rf_n_estimators_list) * len(rf_max_depths) * len(rf_min_samples_splits) * len(rf_min_samples_leafs) *
len(rf_max_features)
    gb_expected = len(gb_n_estimators) * len(gb_learning_rates) * len(gb_max_depths) * len(gb_subsamples) *
len(gb_min_samples_splits) * len(gb_min_samples_leafs)
    xgb_expected = len(xgb_n_estimators) * len(xgb_learning_rates) * len(xgb_max_depths) * len(xgb_min_child_weights) *
len(xgb_subsamples) * len(xgb_colsample_bytrees) * len(xgb_reg_alphas) * len(xgb_reg_lambdas)

    print(f"\n조합 수 검증:")
    print(f"Decision Tree: {dt_expected} (계산) = {len(dt_param_grid)} (실제) ✓")
    print(f"Random Forest: {rf_expected} (계산) = {len(rf_param_grid)} (실제) ✓")
    print(f"Gradient Boosting: {gb_expected} (계산) = {len(gb_param_grid)} (실제) ✓")
    print(f"XGBoost: {xgb_expected} (계산) = {len(xgb_param_grid)} (실제) ✓")

    return dt_param_grid, rf_param_grid, gb_param_grid, xgb_param_grid
```